

TRABAJO FIN DE GRADO

Método de aproximación exterior para optimización de carteras dispersas

Presentado por:
David Gómez Alonso

Supervisado por:
DRA. MARÍA CRISTINA MOLERO DEL RÍO



FACULTAD DE MATEMÁTICAS
Departamento de Estadística e Investigación Operativa
Sevilla, 29 de mayo del 2026

Índice general

Abstract	5
Resumen	7
Introducción	9
1. Optimización de carteras dispersas	11
1.1. Equivalencia entre Selección de Portfolio y Regresión con restricciones	11
1.2. Método de planos de corte	13
1.2.1. La restricción $\ \mathbf{x}\ _0 \leq k$	13
1.2.2. Dualidad y convexidad del problema ($\mathcal{P}_2$)	14
1.2.2.1. Multiplicadores de Lagrange	15
1.2.2.2. Cono tangente y Cuasirregularidad	17
1.2.2.3. Dualidad con restricciones lineales	19
1.2.2.4. Problema dual y convexidad	20
1.2.3. Algoritmo de aproximación exterior	23
2. Complejidad computacional	25
2.1. Introducción a la complejidad computacional	25
2.1.1. Problemas de decisión y clases de complejidad	25
2.2. Complejidad computacional con desigualdades lineales	26
2.3. Complejidad computacional sin desigualdades lineales	29
3. Análisis de sensibilidad	35
4. Resultados computacionales	39
4.1. Implementación	39
4.2. Ejemplo práctico	47
Conclusiones	53
Bibliografía	54

Notación principal

Símbolo	Descripción
$\mathbf{x} \in \mathbb{R}^n$	Vector en $\mathbb{R}^{n-1}$
$\mathbf{X} \in \mathbb{R}^{m \times n}$	Matriz en $\mathbb{R}^{m \times n-2}$
$\ \mathbf{x}\ _0 = \{i : x_i \neq 0\} $	Número de componentes de $\mathbf{x}$ distintas de 0
$\mathcal{Z}_k^n = \{\mathbf{z} \in \{0, 1\}^n : \mathbf{e}^T \mathbf{z} \leq k\}$	Conjunto de vectores binarios con $\ \mathbf{z}\ _0 \leq k$
$Diag(\mathbf{z})$	Matriz con $z_{i,i} = z_i, z_{i,j} = 0, \forall i \neq j$
$\mathbf{e}$	vector de unos del tamaño implícito por el contexto
$\mathbf{I}$	Matriz identidad con dimensión implícita por el contexto
$\mathbb{R}_+^n$	Vectores reales n -dimensionales no negativos
$\mathcal{F}(\mathbf{z})$	Conjunto factible para $\mathbf{z}$ fijo ³
$\mathbf{X} \succ \mathbf{0}$	Matriz en $\mathbb{R}^{n \times m}$ definida positiva
$\mathbf{X} \succeq \mathbf{0}$	Matriz en $\mathbb{R}^{n \times m}$ semidefinida positiva
$Col(\mathbf{A})$	Subespacio vectorial de $\mathbb{R}^m$ generado por las columnas de $\mathbf{A} \in \mathbb{R}^{m \times n}$
$Null(\mathbf{A})$	Subespacio vectorial de $\mathbb{R}^n$ generado por las soluciones del sistema $\mathbf{A}\mathbf{x} = \mathbf{0}, \mathbf{A} \in \mathbb{R}^{m \times n}$
$\nabla f = (\partial_{x_1} f, \dots, \partial_{x_n} f)$	Gradiente de f con $f : \mathbb{R}^n \rightarrow \mathbb{R}$ función escalar

¹Los vectores se denotarán con letras minúsculas en negrita para diferenciarse de los escalares.

²Las matrices se denotarán con letras mayúsculas en negrita para diferenciarse de los vectores y los escalares.

³El conjunto factible usualmente serán los $\mathbf{x} \in \mathbb{R}^n$ que satisfacen las desigualdades lineales y las restricciones de cardinalidad.

Abstract

The portfolio selection process consists of two distinct stages. In the first stage, the expected behavior of a set of assets is estimated. This estimation typically yields an expected return, a measure of volatility, and an expected risk, among other quantities. In this work, we focus on the second stage. We assume that the expected returns and covariance matrix of a previously selected set of assets have been obtained by other means. Our objective is to obtain an optimal selection of these assets by maximizing expected return without exceeding a pre-specified level of risk, which we measure through the variance and covariance of the assets.

We start from Harry Markowitz's mean-variance model and impose two types of constraints. The first set of constraints consists of linear inequalities through which we can adapt the problem to practical financial restrictions. Among others, we may impose constraints on the amount allocated to each asset, adapting to potential liquidity limitations. The second constraint limits the number of selected assets. This restriction is relevant because each asset may incur management costs. Moreover, selecting a too large number of assets may give investors the impression that the strategy is effectively replicating an index.

We will observe that the problem, although seemingly simple, is actually NP-hard. Therefore, a solution based on an outer-approximation algorithm in the style of Marco A. Duran and Ignacio E. Grossmann will be proposed.

Resumen

El proceso de selección de un portfolio consta de dos etapas diferenciadas. En una primera etapa se estima el comportamiento esperado de una serie de activos. En dicha estimación cabe esperar obtener un retorno esperado, una medida de volatilidad, un riesgo esperado, etc. En este trabajo nos vamos a centrar en la segunda etapa. Partimos de haber obtenido por otros medios el retorno esperado y la covarianza de unos activos previamente seleccionados. Nuestro objetivo va a ser obtener una selección óptima de dichos activos maximizando el beneficio esperado sin superar un nivel preseleccionado de riesgo, que mediremos mediante la varianza y covarianza de los activos.

Partiremos del modelo Media-Varianza de Harry Markowitz e impondremos dos tipos de restricciones. El primer conjunto de restricciones constará de desigualdades lineales mediante las cuales podremos ajustar nuestro problema a las restricciones propias de la práctica financiera. Entre otras, podría imponerse restricciones a la cantidad alocada en cada activo adaptándose a las limitaciones de liquidez que pudieran presentar. La segunda desigualdad limita la cantidad de activos seleccionados. Esta imposición es relevante porque cada activo puede ocasionar costes de gestión. Además, en caso de seleccionar una cantidad demasiado grande de activos, puede dar la sensación a los inversores de que realmente lo que se está haciendo es replicar un índice.

Observaremos que el problema, de apariencia sencilla, es en realidad NP-Duro. Por ello se planteará una resolución basada en un algoritmo de aproximación exterior al estilo de Marco A. Duran y Ignacio E. Grossmann.

Introducción

El problema de optimización de carteras Media-Varianza propuesto por Markowitz [15] permite escoger una cartera óptima eligiendo entre n activos distintos con retorno esperado $\boldsymbol{\mu} \in \mathbb{R}^n$ y matriz de varianzas y covarianzas $\boldsymbol{\Sigma} \in S_+^n$. El modelo propuesto por Markowitz permite seleccionar una cartera obteniendo el mayor retorno esperado para una cantidad dada de varianza, resolviendo:

$$\begin{aligned} \min_{\mathbf{x} \in \mathbb{R}_+^n} \quad & \frac{\sigma}{2} \mathbf{x}^T \boldsymbol{\Sigma} \mathbf{x} - \boldsymbol{\mu}^T \mathbf{x} \\ \text{s.a.} \quad & \mathbf{e}^T \mathbf{x} = 1, \end{aligned} \quad (\mathcal{P}_{MV})$$

con $\sigma \geq 0$ un parámetro que controla la relación entre el riesgo y el retorno de la cartera.

Diversas variantes a este modelo se han estudiado. Entre ellas, distintos autores han propuesto restricciones de inversión mínima, inversión máxima, restricciones de cardinalidad, etc. Algunos ejemplos se pueden ver en [7, 12, 17]. Sin embargo, muchas de estas restricciones se implican unas a otras; esto se tratará brevemente en el apartado de complejidad computacional.

Bienstock [5] definió una ampliación del modelo propuesto por Markowitz incluyendo dos conjuntos de desigualdades al problema $(\mathcal{P}_{MV})$. El primer conjunto es un sistema de desigualdades lineales de la forma $\mathbf{l} \leq \mathbf{A}\mathbf{x} \leq \mathbf{u}$ con $\mathbf{l}, \mathbf{u} \in \mathbb{R}^m$, $\mathbf{A} \in \mathbb{R}^{m \times n}$. De esta manera se pueden incluir diversas restricciones del mundo real y garantizar su cumplimiento. El segundo limita el número de activos a escoger a $k \ll n$, imponiendo que la cartera sea k -dispersa, es decir, $\|\mathbf{x}\|_0 \leq k$. Trataremos las distintas motivaciones de cada una de las restricciones en el primer capítulo. En este trabajo nos centraremos en este último problema, el modelo media varianza con restricciones de cardinalidad y desigualdades lineales:

$$\begin{aligned} \min_{\mathbf{x} \in \mathbb{R}_+^n} \quad & \frac{\sigma}{2} \mathbf{x}^T \boldsymbol{\Sigma} \mathbf{x} - \boldsymbol{\mu}^T \mathbf{x} \\ \text{s.a.} \quad & \mathbf{l} \leq \mathbf{A}\mathbf{x} \leq \mathbf{u}, \\ & \mathbf{e}^T \mathbf{x} = 1, \\ & \|\mathbf{x}\|_0 \leq k. \end{aligned} \quad (\mathcal{P}_{MV}^k)$$

Este problema, de apariencia sencilla, es en realidad NP-duro, incluso en ausencia de las desigualdades lineales. Esto será demostrado de forma rigurosa en el tercer

capítulo.

En este trabajo vamos a seguir de cerca el artículo de Dimitris Bertsimas y Ryan Cory-Wright “A Scalable Algorithm for Sparse Portfolio Selection” [3]. Partiremos de introducir un término de regularización ridge. A lo largo del segundo capítulo reformularemos el problema como un problema de regresión lineal múltiple con restricciones de cardinalidad y desigualdades lineales, impondremos la restricción de cardinalidad de una forma muy ventajosa para finalmente proponer un algoritmo de aproximación exterior al estilo de Duran y Grossmann[8] para resolver el problema de manera eficiente y escalable. Posteriormente realizaremos un breve estudio de sensibilidad para concluir que es posible recuperar la solución del problema sin término de regularización.

Finalmente se implementará en C++ el algoritmo y se comprobará de manera empírica la eficiencia del algoritmo con el solver comercial GUROBI.

Capítulo 1

Optimización de carteras dispersas

En este capítulo vamos a tratar el problema $(\mathcal{P}_{MV}^k)$ con un término de regularización Ridge $\frac{1}{2\gamma}\|\mathbf{x}\|_2^2$ con $\gamma > 0$ fijo:

$$\begin{aligned} \min_{\mathbf{x} \in \mathbb{R}_+^n} \quad & \frac{\sigma}{2} \mathbf{x}^T \Sigma \mathbf{x} + \frac{1}{2\gamma} \|\mathbf{x}\|_2^2 - \boldsymbol{\mu}^T \mathbf{x} \\ \text{s.a.} \quad & \mathbf{l} \leq \mathbf{A} \mathbf{x} \leq \mathbf{u} \\ & \mathbf{e}^T \mathbf{x} = 1 \\ & \|\mathbf{x}\|_0 \leq k \end{aligned} \quad (\mathcal{P}_{MV}^{k,\gamma})$$

En lo que sigue, vamos a establecer una equivalencia entre el problema de selección de carteras con restricciones de cardinalidad, desigualdades lineales y término de regularización $(\mathcal{P}_{MV}^{k,\gamma})$ y el problema de regresión lineal múltiple con restricciones de cardinalidad, desigualdades lineales y término de regularización.

Posteriormente cambiaremos la restricción $\|\mathbf{x}\|_0 \leq k$ para que sea más manejable y finalmente trabajaremos con el problema dual, obteniendo dualidad fuerte, y desarrollaremos un algoritmo de planos de corte para resolverlo de forma eficiente.

En el transcurso de este capítulo seguiremos de cerca el artículo “A Scalable Algorithm for Sparse Portfolio Selection” de Dimitris Bertsimas y Ryan Cory-Wright [3]. El algoritmo de resolución que propondremos sigue la idea del método de Aproximación Exterior propuesto por Duran y Grossmann [8].

1.1. Equivalencia entre Selección de Portfolio y Regresión con restricciones

Vamos a escribir el problema $(\mathcal{P}_{MV}^{k,\gamma})$ como un problema de regresión dispersa con restricciones.

Por simplicidad, vamos a redefinir $\Sigma := \sigma \Sigma$. Tenemos que Σ es una matriz semidefinida positiva con $\text{rango}(\Sigma) = r \leq n$. Aplicando la factorización Cholesky,

tenemos que existe al menos una matriz $\mathbf{X} \in \mathbb{R}^{r \times n}$ triangular superior con elementos en la diagonal no negativos de manera que se satisface $\Sigma = \mathbf{X}^T \mathbf{X}$.

De esta manera la función a minimizar en el problema $(\mathcal{P}_{MV}^{k,\gamma})$ queda:

$$\begin{aligned} \frac{\sigma}{2} \mathbf{x}^T \Sigma \mathbf{x} + \frac{1}{2\gamma} \|\mathbf{x}\|_2^2 - \boldsymbol{\mu}^T \mathbf{x} &= \frac{1}{2} \mathbf{x}^T \mathbf{X}^T \mathbf{X} \mathbf{x} + \frac{1}{2\gamma} \|\mathbf{x}\|_2^2 - \boldsymbol{\mu}^T \mathbf{x} \\ &= \underbrace{\frac{1}{2} \|\mathbf{X}\mathbf{x}\|_2^2}_{\text{Cuadrático}} + \underbrace{\frac{1}{2\gamma} \|\mathbf{x}\|_2^2}_{\text{Ridge}} - \boldsymbol{\mu}^T \mathbf{x} \end{aligned} \quad (1.1)$$

* Hemos cambiado Σ por $\sigma \Sigma$.

Queremos expresar el problema de la forma $\min_{\mathbf{x} \in \mathbb{R}_+^n} \frac{1}{2} \|\mathbf{X}\mathbf{x} - \mathbf{y}\|_2^2$. Desarrollando el término, tenemos:

$$\begin{aligned} \frac{1}{2} \|\mathbf{X}\mathbf{x} - \mathbf{y}\|_2^2 &= \frac{1}{2} (\mathbf{X}\mathbf{x} - \mathbf{y})^T (\mathbf{X}\mathbf{x} - \mathbf{y}) \\ &= \frac{1}{2} (\mathbf{x}^T \mathbf{X}^T \mathbf{X} \mathbf{x} - 2\mathbf{x}^T \mathbf{X}^T \mathbf{y} + \mathbf{y}^T \mathbf{y}) \\ &= \frac{1}{2} \underbrace{\|\mathbf{X}\mathbf{x}\|_2^2}_{\text{Cuadrático}} - \mathbf{x}^T \mathbf{X}^T \mathbf{y} + \underbrace{\frac{1}{2} \|\mathbf{y}\|_2^2}_{\text{Constante}}. \end{aligned}$$

Al tratarse de un problema de optimización, podemos ignorar el término constante. Falta ajustar el término $\mathbf{x}^T \mathbf{X}^T \mathbf{y}$. Vamos a descomponer $\boldsymbol{\mu}$ en la suma de su proyección ortogonal sobre $\text{Col}(\mathbf{X}^T)$ y su proyección ortogonal sobre $\text{Null}(\mathbf{X})$. Para ello, vamos a usar los siguientes teoremas del Álgebra lineal:

Teorema 1.1.1. *Sea W un subespacio vectorial de dimensión finita de un espacio vectorial V con producto escalar. Entonces, se tiene $V = W \oplus W^\perp$.*

Demostración. Véase en [16]. □

Teorema 1.1.2. *Sea $A \in \mathbb{R}^{m \times n}$. Entonces $\text{Null}(A)^\perp = \text{Col}(A^T)$.*

Demostración. Véase en [16]. □

Corolario 1.1.1. *Sea $A \in \mathbb{R}^{m \times n}$ se tiene $\mathbb{R}^n = \text{Col}(A^T) \oplus \text{Null}(A)$*

Demostración. Véase en [16]. □

Teorema 1.1.3 (Proyección ortogonal de un vector). *Sea $A \in \mathbb{R}^{m \times n}$ con columnas linealmente independientes, entonces el vector $\hat{x}$ que satiface que $A\hat{x} = \hat{b}$ con $\hat{b}$ la proyección ortogonal de b sobre $\text{col}(A)$ es $\hat{x} = (A^T A)^{-1} A^T b$. Tenemos entonces $\hat{b} = A(A^T A)^{-1} A^T b$.*

Demostración. Véase en [14]. □

Aplicando el Teorema 1.1.3, tenemos que la proyección ortogonal de μ sobre $Col(\mathbf{X}^T)$ es:

$$proy_{Col(\mathbf{X}^T)}(\mu) = \mathbf{X}^T(\mathbf{X}\mathbf{X}^T)^{-1}\mathbf{X}\mu.$$

De esta forma, si definimos $\mathbf{y} := (\mathbf{X}\mathbf{X}^T)^{-1}\mathbf{X}\mu$, tenemos:

$$\mu = \underbrace{\mathbf{X}^T\mathbf{y}}_{\in Col(\mathbf{X}^T)} + \underbrace{(\mu - \mathbf{X}^T\mathbf{y})}_{\in Null(\mathbf{X})} = \mathbf{X}^T\mathbf{y} - (\mathbf{X}^T\mathbf{y} - \mu).$$

Teniendo en cuenta el valor de $\mathbf{y}$, reescribimos el término $\mathbf{X}^T\mathbf{y} - \mu$ como:

$$\mathbf{X}^T\mathbf{y} - \mu = \mathbf{X}^T(\mathbf{X}\mathbf{X}^T)^{-1}\mathbf{X}\mu - \mu = (\mathbf{X}^T(\mathbf{X}\mathbf{X}^T)^{-1}\mathbf{X} - \mathbf{I})\mu.$$

Definimos $\mathbf{d} := (\mathbf{X}^T(\mathbf{X}\mathbf{X}^T)^{-1}\mathbf{X} - \mathbf{I})\mu$. Llegamos a $\mu = \mathbf{X}^T\mathbf{y} - \mathbf{d}$.

Volviendo a (1.1), tenemos:

$$\begin{aligned} \frac{1}{2}\mathbf{x}^T\Sigma\mathbf{x} + \frac{1}{2\gamma}\|\mathbf{x}\|_2^2 - \mu^T\mathbf{x} &= \frac{1}{2}\|\mathbf{X}\mathbf{x}\|_2^2 + \frac{1}{2\gamma}\|\mathbf{x}\|_2^2 - \mu^T\mathbf{x} \\ &= \frac{1}{2}\|\mathbf{X}\mathbf{x}\|_2^2 + \frac{1}{2\gamma}\|\mathbf{x}\|_2^2 - (\mathbf{X}^T\mathbf{y} - \mathbf{d})^T\mathbf{x} \\ &= \frac{1}{2}\|\mathbf{X}\mathbf{x}\|_2^2 + \frac{1}{2\gamma}\|\mathbf{x}\|_2^2 - \mathbf{y}^T\mathbf{X}\mathbf{x} + \mathbf{d}^T\mathbf{x} \\ &= \frac{1}{2}\|\mathbf{X}\mathbf{x}\|_2^2 - \mathbf{x}^T\mathbf{X}^T\mathbf{y} + \frac{1}{2\gamma}\|\mathbf{x}\|_2^2 + \mathbf{d}^T\mathbf{x} \\ &= \frac{1}{2}\|\mathbf{X}\mathbf{x} - \mathbf{y}\|_2^2 - \underbrace{\frac{1}{2}\|\mathbf{y}\|_2^2}_{Constante} + \frac{1}{2\gamma}\|\mathbf{x}\|_2^2 + \mathbf{d}^T\mathbf{x} \end{aligned}$$

De esta forma, observamos que nuestro problema $(\mathcal{P}_{MV}^{k,\gamma})$ es equivalente al siguiente problema de regresión dispersa con restricciones:

$$\begin{aligned} \min_{\mathbf{x} \in \mathbb{R}_+^n} \quad & \frac{1}{2\gamma}\|\mathbf{x}\|_2^2 + \frac{1}{2}\|\mathbf{X}\mathbf{x} - \mathbf{y}\|_2^2 + \mathbf{d}^T\mathbf{x} \\ \text{s.a.} \quad & \mathbf{l} \leq \mathbf{A}\mathbf{x} \leq \mathbf{u} \\ & \mathbf{e}^T\mathbf{x} = 1 \\ & \|\mathbf{x}\|_0 \leq k. \end{aligned} \quad (\mathcal{P}_{Reg}^k)$$

1.2. Método de planos de corte

1.2.1. La restricción $\|\mathbf{x}\|_0 \leq k$

Proposición 1.2.1. *La restricción $\|\mathbf{x}\|_0 \leq k$ no es convexa.*

Demostración. Basta observar que dado $k = 1$ y dados $x^{(1)} = (1, 0)$, $x^{(2)} = (0, 1)$ en $\mathbb{R}^2$, satisfacen $\|x^{(1)}\|_0 = \|x^{(2)}\|_0 \leq k = 1$, sin embargo $\frac{1}{2}(x^{(1)} + x^{(2)}) = (0.5, 0.5)$ con $\|(0.5, 0.5)\|_0 = 2 \not\leq k = 1$. De esta forma el conjunto $S = \{x \in \mathbb{R}^n : \|x\|_0 \leq k\}$ no satisface $\lambda x + (1 - \lambda)y \in S$, $\forall x, y \in S$, $\forall \lambda \in [0, 1]$ y por tanto no es convexo. $\square$

Este problema se ha intentado resolver con distintas estrategias. Un enfoque recurrente ha sido introducir las variables binarias z_i que modelan si x_i toman valores distintos de cero. Basta con imponer que $x_i = 0$ si $z_i = 0$. Esto se puede hacer de manera sencilla añadiendo las restricciones lineales $e^T z \leq k$ y $x_i \leq z_i$. Sin embargo, vamos a seguir una estrategia distinta. Vamos a sustituir en $(\mathcal{P}_{MV}^{k,\gamma})$ los términos x_i por $x_i z_i$. De esta forma, imponemos la restricción $x_i = 0$ si $z_i = 0$ de una manera más manejable. Obtenemos así el siguiente problema equivalente:

$$\min_{z \in \mathcal{Z}_k^n} [f(z)] \quad (\mathcal{P}_1)$$

con

$$\begin{aligned} f(z) : &= \min_{x \in \mathbb{R}^n} \frac{1}{2\gamma} x^T x + \frac{1}{2} \|XZx - y\|_2^2 + d^T Zx \\ \text{s.a. } &1 \leq AZx \leq u \\ &e^T Zx = 1 \\ &Zx \geq 0 \end{aligned} \quad (\mathcal{P}_2)$$

donde $Z = \text{Diag}(z)$ es una matriz diagonal satisfaciendo $Z_{i,i} = z_i$.

Es importante observar que no hemos incluido el término Z con $\frac{1}{2\gamma} x^T x$ para imponer la restricción $x_i = 0$ si $z_i = 0$. Eso se debe al siguiente resultado:

Lema 1.2.1. *Sea $z \in \mathcal{Z}_k^n$. Entonces, cualquier solución óptima x^* del subproblema $(\mathcal{P}_2)$ satisface que, si $z_i = 0$, entonces $x_i = 0$.*

Demostración. Supongamos que $z_i = 0$. Vamos a ver que x_i debe ser necesariamente nulo. Supongamos que x^* es solución del subproblema generado por $f(z)$. Como $z_i = 0$, el único término de la función a minimizar al que afecta x_i es a $\frac{1}{2\gamma} x^T x$. El término correspondiente a x_i sería $\frac{1}{2\gamma} x_i^2$ que alcanza el mínimo cuando $x_i = 0$. Observamos que, al ser $z_i = 0$, variar x_i no afecta a la factibilidad de la solución. $\square$

1.2.2. Dualidad y convexidad del problema $(\mathcal{P}_2)$

Esta nueva formulación $(\mathcal{P}_2)$ parece solventar la no convexidad del conjunto factible generado por la restricción $\|x\|_0 \leq k$ a costa de obtener una función objetivo no convexa. Sin embargo, gracias a la estructura lineal de las restricciones, tenemos garantizada dualidad fuerte y veremos que el problema dual es convexo.

Para ello, es necesario presentar primero resultados de Programación no lineal. Vamos a seguir el libro Nonlinear Programming de Dimitri P. Bertsekas [2].

1.2.2.1. Multiplicadores de Lagrange

Condiciones necesarias con restricciones de igualdad

Consideramos el problema con restricciones de la forma

$$\begin{aligned} \min_{\mathbf{x} \in \mathbb{R}^n} \quad & f(\mathbf{x}) \\ \text{s.a.} \quad & h_i(\mathbf{x}) = 0, \quad i = 1, \dots, m. \end{aligned} \quad (\text{Min-Ig})$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$, $h_i : \mathbb{R}^n \rightarrow \mathbb{R}$ son funciones continuamente diferenciables. Definimos $h(\mathbf{x}) = (h_1(\mathbf{x}), \dots, h_m(\mathbf{x}))$, por lo que las restricciones quedarían $h(\mathbf{x}) = 0$.

Definición 1.2.1. Un vector factible $\mathbf{x}$ se dice regular si el conjunto $\{\nabla h_1(\mathbf{x}), \dots, \nabla h_m(\mathbf{x})\}$ es linealmente independiente.

Teorema 1.2.1 (Teorema de los multiplicadores de Lagrange - Condiciones necesarias). Sea $\mathbf{x}^*$ un mínimo local de f satisfaciendo $h(\mathbf{x}) = 0$ y, además, punto regular. Entonces existe un único vector $\boldsymbol{\lambda}^* = (\lambda_1^*, \dots, \lambda_m^*) \in \mathbb{R}^m$, llamado vector de multiplicadores de Lagrange, tal que

$$\nabla f(\mathbf{x}^*) + \sum_{i=1}^m \lambda_i \nabla h_i(\mathbf{x}^*) = 0.$$

Además si $f, h \in C^2$ tenemos

$$\mathbf{y}^T (\nabla^2 f(\mathbf{x}^*) + \sum_{i=1}^m \lambda_i^* \nabla^2 h_i(\mathbf{x}^*)) \mathbf{y} \geq 0 \quad \forall \mathbf{y} \in V(\mathbf{x}^*)$$

donde $V(\mathbf{x}^*) = \{\mathbf{y} : \nabla h_i(\mathbf{x}^*)^T \mathbf{y} = 0, i = 1, \dots, m\}$.

La función Lagrangiana

Definición 1.2.2. Definimos la función Lagrangiana del problema (Min-Ig) como la función: $\mathcal{L} : \mathbb{R}^n \rightarrow \mathbb{R}$

$$\mathcal{L}(\mathbf{x}, \boldsymbol{\lambda}) = f(\mathbf{x}) + \sum_{i=1}^m \lambda_i h_i(\mathbf{x}).$$

De esta forma, si $\mathbf{x}^*$ es un mínimo local regular, por el Teorema 1.2.1 se tiene:

$$\nabla_{\mathbf{x}} \mathcal{L}(\mathbf{x}^*, \boldsymbol{\lambda}^*) = \nabla f(\mathbf{x}^*) + \sum_{i=1}^m \lambda_i \nabla h_i(\mathbf{x}^*) = 0$$

$$\nabla_{\boldsymbol{\lambda}} \mathcal{L}(\mathbf{x}^*, \boldsymbol{\lambda}^*) = h(\mathbf{x}^*) = 0$$

$$\mathbf{y}^T \nabla_{xx}^2 \mathcal{L}(\mathbf{x}^*, \boldsymbol{\lambda}^*) \mathbf{y} \geq 0, \quad \forall \mathbf{y} \in V(\mathbf{x}^*)$$

Condiciones suficientes con restricciones de igualdad

Teorema 1.2.2 (Condiciones suficientes de segundo orden). *Supongamos que $f, h \in C^2$ y sean $\mathbf{x}^* \in \mathbb{R}^n$ y $\boldsymbol{\lambda}^* \in \mathbb{R}^m$ satisfaciendo*

$$\begin{aligned} \nabla_{\mathbf{x}} \mathcal{L}(\mathbf{x}^*, \boldsymbol{\lambda}^*) &= 0, \quad \nabla_{\boldsymbol{\lambda}} \mathcal{L}(\mathbf{x}^*, \boldsymbol{\lambda}^*) = 0 \\ \mathbf{y}^T \nabla_{\mathbf{xx}}^2 \mathcal{L}(\mathbf{x}^*, \boldsymbol{\lambda}^*) \mathbf{y} &> 0, \quad \forall \mathbf{y} \neq 0, \quad \nabla h(\mathbf{x}^*)^T \mathbf{y} = 0 \end{aligned}$$

Entonces $\mathbf{x}^$ es un mínimo local estricto de f satisfaciendo $h(\mathbf{x}^*) = 0$. De hecho, existen escalares $\gamma > 0$ y $\varepsilon > 0$ tales que*

$$f(\mathbf{x}) \geq f(\mathbf{x}^*) + \frac{\gamma}{2} \|\mathbf{x} - \mathbf{x}^*\|^2, \quad \forall \mathbf{x} \text{ satisfaciendo } h(\mathbf{x}) = 0 \text{ y } \|\mathbf{x} - \mathbf{x}^*\| < \varepsilon.$$

Restricciones de desigualdad

Vamos a considerar ahora el problema con restricciones tanto de igualdad como de desigualdad:

$$\begin{aligned} \min_{\mathbf{x} \in \mathbb{R}^n} \quad & f(\mathbf{x}) \\ \text{s.a.} \quad & h(\mathbf{x}) = 0, \\ & g(\mathbf{x}) \leq 0, \end{aligned} \quad (\text{Min-Des})$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$, $g : \mathbb{R}^n \rightarrow \mathbb{R}^r$, $h : \mathbb{R}^n \rightarrow \mathbb{R}^m$ son funciones continuamente diferenciables.

Definición 1.2.3 (Función Lagrangiana del problema con restricciones de desigualdad). *Definimos la función Lagrangiana del problema (Min-Des) como la función $\mathcal{L} : \mathbb{R}^n \rightarrow \mathbb{R}$*

$$\mathcal{L}(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\mu}) = f(\mathbf{x}) + \sum_{i=1}^m \lambda_i h_i(\mathbf{x}) + \sum_{j=1}^r \mu_j g_j(\mathbf{x}).$$

Teorema 1.2.3 (Condiciones necesarias Karush-Kuhn-Tucker). *Sea $\mathbf{x}^*$ un mínimo local del problema (Min-Des) y supongamos que $\mathbf{x}^*$ es regular. Entonces existen unos únicos vectores multiplicadores de Lagrange $\boldsymbol{\lambda}^* = (\lambda_1^*, \dots, \lambda_m^*)$, $\boldsymbol{\mu}^* = (\mu_1^*, \dots, \mu_r^*)$ tales que*

$$\begin{aligned} \nabla_{\mathbf{x}} \mathcal{L}(\mathbf{x}^*, \boldsymbol{\lambda}^*, \boldsymbol{\mu}^*) &= 0, \\ \mu_j &\geq 0, \quad j = 1, \dots, r, \\ \mu_j &= 0, \quad \forall j \in A(\mathbf{x}^*) \end{aligned}$$

donde $A(\mathbf{x}^*) = \{j : g_j(\mathbf{x}^*) = 0\}$ es el conjunto de restricciones activas.

Además, si $f, g, h \in C^2$ se tiene:

$$\begin{aligned} \mathbf{y}^T \nabla_{\mathbf{xx}}^2 \mathcal{L}(\mathbf{x}^*, \boldsymbol{\lambda}^*, \boldsymbol{\mu}^*) \mathbf{y} &\geq 0, \quad \forall \mathbf{y} \in \mathbb{R}^n \text{ satisfaciendo } \nabla h_i(\mathbf{x}^*)^T \mathbf{y} = 0, \quad \forall i = 1, \dots, m, \\ &\quad \nabla g_j(\mathbf{x}^*)^T \mathbf{y} = 0, \quad \forall j \in A(\mathbf{x}^*). \end{aligned}$$

Teorema 1.2.4 (Condiciones Karush-Kuhn-Tucker Reforzadas). *Sea $\mathbf{x}^*$ un mínimo local del problema (Min-Des), supongamos que $\mathbf{x}^*$ es regular. Entonces existen multiplicadores de Lagrange $\lambda_1^*, \dots, \lambda_m^*$ y $\mu_1^*, \dots, \mu_r^*$ satisfaciendo:*

1.

$$\nabla f(\mathbf{x}^*) + \sum_{i=1}^m \lambda_i^* \nabla h_i(\mathbf{x}^*) + \sum_{j=1}^r \mu_j^* \nabla g_j(\mathbf{x}^*) = 0.$$

2. $\mu_j^* \geq 0$ para todo $j = 1, \dots, r$.

3. *En cada vecindario N de $\mathbf{x}^*$ existe $\mathbf{x} \in N$ tal que $\lambda_i^* h_i(\mathbf{x}) > 0$ para todo i con $\lambda_i^* \neq 0$ y $\mu_j^* g_j > 0$ para todo j con $\mu_j^* \neq 0$. Además, si $(\lambda_j^*, \mu_j^*) \neq (0, 0)$, x puede ser escogido tal que $f(\mathbf{x}) < f(\mathbf{x}^*)$.*

Teorema 1.2.5 (Condiciones suficientes de segundo orden). *Consideremos el problema (Min-Des), supongamos que $f, g, h \in C^2$, y sea $\mathbf{x}^* \in \mathbb{R}^n$, $\boldsymbol{\lambda}^* \in \mathbb{R}^m$ y $\boldsymbol{\mu}^* \in \mathbb{R}^r$ satisfaciendo*

$$\begin{aligned} \nabla_{\mathbf{x}} \mathcal{L}(\mathbf{x}^*, \boldsymbol{\lambda}^*, \boldsymbol{\mu}^*) &= 0, & h(\mathbf{x}^*) &= 0, & g(\mathbf{x}^*) &\leq 0, \\ \mu_j^* &\geq 0, & j &= 1, \dots, r, \\ \mu_j^* &= 0, & \forall j &\notin A(\mathbf{x}^*), \\ \mathbf{y}^T \nabla_{\mathbf{xx}}^2 \mathcal{L}(\mathbf{x}^*, \boldsymbol{\lambda}^*, \boldsymbol{\mu}^*) \mathbf{y} &> 0, & \forall \mathbf{y} \neq 0 & \text{ satisfaciendo } \nabla h_i(\mathbf{x}^*)^T \mathbf{y} = 0, \forall i = 1, \dots, m \\ & & & \nabla g_j(\mathbf{x}^*)^T \mathbf{y} = 0, \forall j \in A(\mathbf{x}^*) \end{aligned}$$

Supongamos, además, que

$$\mu_j^* > 0, \quad \forall j \in A(\mathbf{x}^*).$$

Entonces $\mathbf{x}^$ es un mínimo local estricto satisfaciendo $h(\mathbf{x}^*) = 0$ y $g(\mathbf{x}^*) \leq 0$.*

1.2.2.2. Cono tangente y Cuasirregularidad

Hasta ahora hemos supuesto en todo momento que $\mathbf{x}^*$ factible es regular. Sin embargo, esto supone una restricción que no siempre se cumple. Por ello, vamos a introducir el concepto de cuasirregularidad que más adelante veremos que nuestro problema satisface.

Definición 1.2.4 (Cono tangente). *Dados $X \subset \mathbb{R}^n$ y $\mathbf{x} \in X$, definimos el cono tangente de X en x como el conjunto de todas las tangentes de X en x . Lo denotamos como*

$$T(\mathbf{x}) = \{\mathbf{y} \in \mathbb{R}^n : \mathbf{y} \text{ tangente a } X \text{ en } \mathbf{x}\}.$$

Proposición 1.2.2 (Condiciones del cono tangente para la optimalidad). *Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función y sea $X \subset \mathbb{R}^n$. Supongamos que f es continuamente diferenciable sobre un conjunto abierto conteniendo a X y sea $\mathbf{x}^*$ un mínimo local de f sobre X . Entonces se cumple que*

$$\nabla f(\mathbf{x}^*)^T \mathbf{y} \geq 0, \quad \forall \mathbf{y} \in T(\mathbf{x}^*).$$

Definición 1.2.5 (Cono de variaciones factibles de primer orden en $\mathbf{x}$). *Definimos el cono de variaciones factibles de primer orden en $\mathbf{x}$ como*

$$V(\mathbf{x}) = \{\mathbf{y} \mid \nabla h_i(\mathbf{x})^T \mathbf{y} = 0, \quad i = 1, \dots, m, \quad \nabla g_j(\mathbf{x})^T \mathbf{y} \leq 0, \quad j \in A(\mathbf{x})\}.$$

Proposición 1.2.3 (Condiciones necesarias y suficientes para la existencia de los multiplicadores de Lagrange). *Sea $\mathbf{x}^*$ un mínimo local del problema (Min-Des). Entonces existen multiplicadores de Lagrange $\lambda_1^*, \dots, \lambda_m^*$ y $\mu_1^*, \dots, \mu_r^*$ satisfaciendo*

$$\begin{aligned} \nabla f(\mathbf{x}^*) + \sum_{i=1}^m \lambda_i^* \nabla h_i(\mathbf{x}^*) + \sum_{j=1}^r \mu_j^* \nabla g_j(\mathbf{x}^*) &= 0, \\ \mu_j^* &\geq 0, \quad j = 0, 1, \dots, r, \quad \mu_j^* = 0, \quad j \notin A(\mathbf{x}^*) \end{aligned}$$

si y sólo si

$$\nabla f(\mathbf{x}^*)^T \mathbf{y} \geq 0, \quad \forall \mathbf{y} \in V(\mathbf{x}^*).$$

Cuasirregularidad

Definición 1.2.6 (Cuasirregularidad). *Consideramos el conjunto de puntos factibles $C = \{\mathbf{x} \mid h_1(\mathbf{x}) = 0, \dots, h_m(\mathbf{x}) = 0, g_1(\mathbf{x}) \leq 0, \dots, g_r(\mathbf{x}) \leq 0\}$.*

Un vector factible $\mathbf{x}$ se dice cuasiregular si el cono tangente de C en $\mathbf{x}$ es igual al cono de variaciones factibles de primer orden en $\mathbf{x}$, es decir:

$$T(\mathbf{x}) = V(\mathbf{x}).$$

Proposición 1.2.4. *Sea $\mathbf{x}^*$ un mínimo local del problema (Min-Des). Si $\mathbf{x}^*$ es un punto cuasirregular, entonces existen multiplicadores de Lagrange $\lambda_1^*, \dots, \lambda_m^*$ y $\mu_1^*, \dots, \mu_r^*$ satisfaciendo*

$$\begin{aligned} \nabla f(\mathbf{x}^*) + \sum_{i=1}^m \lambda_i^* \nabla h_i(\mathbf{x}^*) + \sum_{j=1}^r \mu_j^* \nabla g_j(\mathbf{x}^*) &= 0, \\ \mu_j^* &\geq 0, \quad j = 1, \dots, r, \quad \mu_j^* = 0, \quad j \notin A(\mathbf{x}^*). \end{aligned}$$

Proposición 1.2.5 (Restricciones Lineales/Cóncavas). *Sea $\mathbf{x}^*$ un mínimo local del Problema (Min-Des). Supongamos que las funciones h_i son lineales y las funciones g_j son cóncavas. Entonces $\mathbf{x}^*$ satisface las condiciones necesarias del Teorema 1.2.4*

Demostración. Véase en [2]. □

Observación 1. En esta sección hemos demostrado que, en un problema con restricciones estrictamente lineales, todo punto es pseudonormal y, por tanto, los mínimos cumplen las condiciones KKT. En el artículo de D. Bertsimas y R. Cory-Wright se habla de Restricciones Abadie (cuasirregularidad). La pseudonormalidad implica la cuasirregularidad.




Figura 1.1: Distintas condiciones que garantizan la existencia de multiplicadores de Lagrange.

1.2.2.3. Dualidad con restricciones lineales

Consideremos el siguiente problema:

$$\begin{aligned}
 & \min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}) \\
 & \text{s.a. } \mathbf{Ax} \leq \mathbf{b} \\
 & \quad \mathbf{Px} = \mathbf{d} \quad i = 1, \dots, m, \quad \mathbf{x} \in X
 \end{aligned}
 \tag{Primal}$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es una función convexa continuamente diferenciable y X un conjunto poliédrico. Vamos a referirnos a este problema como problema primal.

Consideramos la función Lagrangiana

$$\mathcal{L}(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\mu}) = f(\mathbf{x}) + \sum_{i=1}^m \lambda_i (\mathbf{p}_i^T \mathbf{x} - d_i) + \sum_{j=1}^r \mu_j (\mathbf{a}_j^T \mathbf{x} - b_j),$$

donde $\mathbf{a}_i^T, \mathbf{p}_i^T$ denotan la i -ésima fila de las matrices A y P , respectivamente.

Definimos la función dual del problema:

$$q(\boldsymbol{\lambda}, \boldsymbol{\mu}) = \inf_{\mathbf{x} \in X} \mathcal{L}(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\mu}).$$

El problema dual es

$$\max_{\boldsymbol{\lambda} \in \mathbb{R}^n, \boldsymbol{\mu} \in \mathbb{R}_+^m} q(\boldsymbol{\lambda}, \boldsymbol{\mu}). \quad (\text{Dual})$$

Teorema 1.2.6 (Dualidad fuerte con restricciones lineales). *Si el problema (Primal) tiene solución óptima, el problema (Dual) también tiene solución óptima y los valores correspondientes son iguales.*

Demostración. Véase en [2]. □

El caso Convexo

Por último, vamos a introducir un resultado esencial para el caso en el que tanto la función como el conjunto de restricciones son convexos.

Teorema 1.2.7. *Sea $X \subset \mathbb{R}^n$ y sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa sobre X , entonces un mínimo local de f sobre X es un mínimo global. Además, si f es estrictamente convexa sobre X , entonces f tiene como máximo un mínimo global sobre X . Además, si f es fuertemente convexa y X es cerrado, entonces f tiene un único mínimo global en X .*

1.2.2.4. Problema dual y convexidad

Vamos a reescribir el problema $(\mathcal{P}_1)$ como un problema de punto de silla.

Teorema 1.2.8. *Supongamos que el problema $(\mathcal{P}_1)$ es factible. Entonces es equivalente al siguiente problema:*

$$\begin{aligned} \min_{\mathbf{z} \in \mathbb{Z}_k^n} \quad & \max_{\substack{\boldsymbol{\alpha} \in \mathbb{R}^r, \boldsymbol{\omega} \in \mathbb{R}^n, \\ \boldsymbol{\beta}_l, \boldsymbol{\beta}_u \in \mathbb{R}_+^m, \lambda \in \mathbb{R}}} -\frac{1}{2} \boldsymbol{\alpha}^T \boldsymbol{\alpha} - \frac{\gamma}{2} \sum_i z_i \omega_i^2 + \mathbf{y}^T \boldsymbol{\alpha} + \boldsymbol{\beta}_l^T \mathbf{l} - \boldsymbol{\beta}_u^T \mathbf{u} + \lambda \\ \text{s.a.} \quad & \boldsymbol{\omega} \geq \mathbf{X}^T \boldsymbol{\alpha} + \mathbf{A}^T (\boldsymbol{\beta}_l + \boldsymbol{\beta}_u) + \lambda \mathbf{e} - \mathbf{d} \end{aligned}$$

Demostración. Consideremos el vector de variables auxiliar $\mathbf{r}$ tal que $\mathbf{r} = \mathbf{y} - \mathbf{XZx}$ y reescribimos el problema $(\mathcal{P}_1)$ de la siguiente forma:

$$\begin{aligned}
 \min_{\mathbf{z} \in \mathcal{Z}_n^k, \mathbf{x} \in \mathbb{R}^n, \mathbf{r} \in \mathbb{R}^r} \quad & \frac{1}{2\gamma} \|\mathbf{x}\|_2^2 + \frac{1}{2} \|\mathbf{r}\|_2^2 + \mathbf{d}^T \mathbf{Zx} \\
 \text{s.a.} \quad & \mathbf{y} - \mathbf{XZx} = \mathbf{r} & [\boldsymbol{\alpha}] \\
 & \mathbf{AZx} \geq \mathbf{l} & [\boldsymbol{\beta}_l] \\
 & \mathbf{AZx} \leq \mathbf{u} & [\boldsymbol{\beta}_u] \\
 & \mathbf{e}^T \mathbf{Zx} = 1 & [\lambda] \\
 & \mathbf{Zx} \geq \mathbf{0} & [\boldsymbol{\pi}]
 \end{aligned} \tag{1.2}$$

donde hemos escrito entre corchetes el vector de variables duales asociado a cada restricción. Tenemos $\boldsymbol{\alpha} \in \mathbb{R}^r$, $\boldsymbol{\omega} \in \mathbb{R}^n$, $\boldsymbol{\beta}_l, \boldsymbol{\beta}_u \in \mathbb{R}_+^m$, $\lambda \in \mathbb{R}$ y $\boldsymbol{\pi} \in \mathbb{R}_+^n$.

Consideramos el Lagrangiano asociado a este problema:

$$\begin{aligned}
 \mathcal{L}(\mathbf{x}, \lambda, \boldsymbol{\mu}, \boldsymbol{\pi}, \boldsymbol{\beta}_l, \boldsymbol{\beta}_u) &= \frac{1}{2\gamma} \mathbf{x}^T \mathbf{x} + \frac{1}{2} \mathbf{r}^T \mathbf{r} + \mathbf{d}^T \mathbf{Zx} + \boldsymbol{\alpha}^T (\mathbf{y} - \mathbf{XZx} - \mathbf{r}) - \boldsymbol{\pi}^T \mathbf{Zx} \\
 &\quad - \lambda (\mathbf{e}^T \mathbf{Zx} - 1) - \boldsymbol{\beta}_l^T (\mathbf{AZx} - \mathbf{l}) + \boldsymbol{\beta}_u^T (\mathbf{AZx} - \mathbf{u}) \\
 &= \underbrace{\frac{1}{2} \mathbf{x}^T \mathbf{x}}_{\text{Término cuadrático en } \mathbf{x}} + \underbrace{\frac{1}{2} \mathbf{r}^T \mathbf{r}}_{\text{Término cuadrático en } \mathbf{r}} + \underbrace{(-\mathbf{X}^T \boldsymbol{\alpha} - \boldsymbol{\pi} - \lambda \mathbf{e} - \mathbf{A}^T (\boldsymbol{\beta}_l - \boldsymbol{\beta}_u) + \mathbf{d}) \mathbf{Zx}}_{\text{Término lineal en } \mathbf{x}} \\
 &\quad - \underbrace{\boldsymbol{\alpha}^T \mathbf{r}}_{\text{Término lineal en } \mathbf{x}} + \underbrace{\boldsymbol{\alpha}^T \mathbf{y} + \lambda + \boldsymbol{\beta}_l^T \mathbf{l} - \boldsymbol{\beta}_u^T \mathbf{u}}_{\text{Término constante}}.
 \end{aligned}$$

Para $\mathbf{z}$ fijo, el problema interno de minimización tiene restricciones lineales, tenemos por tanto pseudonormalidad, por lo que podemos calcular el mínimo aplicando el Teorema 1.2.3:

$$\begin{aligned}
 \nabla_{\mathbf{x}} \mathcal{L} = 0 &\implies \frac{1}{2} \mathbf{x} + \gamma \mathbf{Z} (\mathbf{d} - \mathbf{X}^T \boldsymbol{\alpha} - \boldsymbol{\pi} - \lambda \mathbf{e} - \mathbf{A}^T (\boldsymbol{\beta}_l - \boldsymbol{\beta}_u)) = \mathbf{0} \\
 &\implies \mathbf{x} = \mathbf{Z} (\mathbf{X}^T \boldsymbol{\alpha} + \boldsymbol{\pi} + \lambda \mathbf{e} + \mathbf{A}^T (\boldsymbol{\beta}_l - \boldsymbol{\beta}_u) - \mathbf{d})
 \end{aligned}$$

$$\nabla_{\mathbf{r}} \mathcal{L} = 0 \implies \mathbf{r} - \boldsymbol{\alpha} = \mathbf{0} \implies \mathbf{r} = \boldsymbol{\alpha}$$

Sustituimos en $\mathcal{L}$ para obtener la expresión de la función dual. Primero introducimos la variable auxiliar $\boldsymbol{\omega} = \mathbf{X}^T \boldsymbol{\alpha} + \lambda \mathbf{e} + \mathbf{A}^T (\boldsymbol{\beta}_l - \boldsymbol{\beta}_u) - \mathbf{d} + \boldsymbol{\pi}$ con $\boldsymbol{\pi} \geq \mathbf{0}$. Observamos que podemos eliminar $\boldsymbol{\pi}$ incluyendo la siguiente restricción de desigualdad en vez de la igualdad anterior $\boldsymbol{\omega} \geq \mathbf{X}^T \boldsymbol{\alpha} + \lambda \mathbf{e} + \mathbf{A}^T (\boldsymbol{\beta}_l - \boldsymbol{\beta}_u) - \mathbf{d}$. De esta forma, nos queda

$$\begin{aligned}
 q(\lambda, \boldsymbol{\mu}, \boldsymbol{\beta}_l, \boldsymbol{\beta}_u) &= \frac{1}{2} \boldsymbol{\alpha}^T \boldsymbol{\alpha} - \boldsymbol{\alpha}^T \boldsymbol{\alpha} + \frac{1}{2\gamma} (\gamma \mathbf{Z} \boldsymbol{\omega})^T (\gamma \mathbf{Z} \boldsymbol{\omega}) - \gamma \boldsymbol{\omega}^T \mathbf{Z} \mathbf{Z} \boldsymbol{\omega} + \boldsymbol{\alpha}^T \mathbf{y} + \boldsymbol{\beta}_l^T \mathbf{l} - \boldsymbol{\beta}_u^T \mathbf{u} + \lambda \\
 &= -\frac{1}{2} \boldsymbol{\alpha}^T \boldsymbol{\alpha} - \frac{\gamma}{2} \boldsymbol{\omega}^T \mathbf{Z}^2 \boldsymbol{\omega} + \mathbf{y}^T \boldsymbol{\alpha} + \boldsymbol{\beta}_l^T \mathbf{l} - \boldsymbol{\beta}_u^T \mathbf{u} + \lambda.
 \end{aligned}$$

Observamos que $\mathbf{z}$, al ser un vector binario, cumple $z_i^2 = z_i$. Por tanto, llegamos al problema dual

$$f(\mathbf{z}) = \max_{\substack{\boldsymbol{\alpha} \in \mathbb{R}^r, \boldsymbol{\omega} \in \mathbb{R}^n, \\ \boldsymbol{\beta}_l, \boldsymbol{\beta}_u \in \mathbb{R}_+^m, \lambda \in \mathbb{R}}} -\frac{1}{2} \boldsymbol{\alpha}^T \boldsymbol{\alpha} - \frac{\gamma}{2} \sum_i z_i \omega_i^2 + \mathbf{y}^T \boldsymbol{\alpha} + \boldsymbol{\beta}_l^T \mathbf{1} - \boldsymbol{\beta}_u^T \mathbf{u} + \lambda$$

s.a. $\boldsymbol{\omega} \geq \mathbf{X}^T \boldsymbol{\alpha} + \mathbf{A}^T(\boldsymbol{\beta}_l + \boldsymbol{\beta}_u) + \lambda \mathbf{e} - \mathbf{d}.$

Observamos que el problema dual es factible porque $\boldsymbol{\omega}$ puede crecer sin límite. Por el Teorema 1.2.6, la solución del problema dual coincide con la solución del problema primal siempre que este último sea factible. Por tanto, para cada $\mathbf{z} \in \mathcal{Z}_n^k$ fijo, el problema interno de minimización es infactible o tiene dualidad fuerte.

De esta forma, minimizando $f(\mathbf{z})$ en $\mathcal{Z}_n^k$, tenemos el resultado buscado, ignorando las elecciones de $\mathbf{z}$ infactibles para el problema primal interno. En estos casos, por dualidad débil, tenemos que si el problema primal es infactible, el dual es no acotado y una elección de $\mathbf{z}$ con $f(\mathbf{z}) = +\infty$ nunca va a ser óptima para un problema de minimización. $\square$

Corolario 1.2.1. $f(\mathbf{z})$ es convexa en $\mathbf{z}$.

Demostración. Hemos reescrito $f(\mathbf{z})$ como el máximo puntual de funciones lineales en $\mathbf{z}$. Tenemos que el máximo puntual de funciones convexas es convexo. Véase [6]. $\square$

Definición 1.2.7 (Subgradiente). *Dado un conjunto convexo $X \subseteq \mathbb{R}^n$ y una función convexa $f : X \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$, se dice que un vector $\mathbf{v} \in \mathbb{R}^n$ es un subgradiente de la función en el punto $\mathbf{x}_0 \in X$ si:*

$$f(\mathbf{x}) \geq f(\mathbf{x}_0) + \mathbf{v} \cdot (\mathbf{x} - \mathbf{x}_0) \quad \forall \mathbf{x} \in X.$$

Definimos así el conjunto de subgradientes de f en un punto:

$$\partial f(\mathbf{x}_0) = \{\mathbf{v} \in \mathbb{R}^n : \mathbf{v} \text{ subgradiente de } f \text{ en } \mathbf{x}_0\}.$$

Corolario 1.2.2. *Sea $\boldsymbol{\omega}^*(\mathbf{z})$ una elección óptima de $\boldsymbol{\omega}$ para una elección de activos $\mathbf{z}$. Entonces, un subgradiente válido $\mathbf{g}_z \in \partial f(\mathbf{z})$ tiene componentes de la forma:*

$$g_{z,i} = -\frac{\gamma}{2} \omega_i^*(\mathbf{z})^2.$$

Demostración. Sea $\mathbf{z}^* \in \mathcal{Z}_n^k$ y sea $(\boldsymbol{\alpha}^*, \boldsymbol{\omega}^*, \boldsymbol{\beta}_l^*, \boldsymbol{\beta}_u^*, \lambda)$ el vector solución del problema dual. Sea $\mathbf{z} \in \mathcal{Z}_n^k$ tenemos que $(\boldsymbol{\alpha}^*, \boldsymbol{\omega}^*, \boldsymbol{\beta}_l^*, \boldsymbol{\beta}_u^*, \lambda)$ es una solución factible del problema dual para $\mathbf{z}$. Tenemos entonces

$$\begin{aligned} f(\mathbf{z}) &= \max_{\substack{\boldsymbol{\alpha} \in \mathbb{R}^r, \boldsymbol{\omega} \in \mathbb{R}^n, \\ \boldsymbol{\beta}_l, \boldsymbol{\beta}_u \in \mathbb{R}_+^m, \lambda \in \mathbb{R}}} \overbrace{-\frac{1}{2} \boldsymbol{\alpha}^T \boldsymbol{\alpha} + \mathbf{y}^T \boldsymbol{\alpha} + \boldsymbol{\beta}_l^T \mathbf{1} - \boldsymbol{\beta}_u^T \mathbf{u} + \lambda - \frac{\gamma}{2} \sum_i z_i \omega_i^2}^{D(\boldsymbol{\alpha}, \boldsymbol{\omega}, \boldsymbol{\beta}_l, \boldsymbol{\beta}_u, \lambda; \mathbf{z})} \\ &\geq D(\boldsymbol{\alpha}^*, \boldsymbol{\omega}^*, \boldsymbol{\beta}_l^*, \boldsymbol{\beta}_u^*, \lambda; \mathbf{z}) \end{aligned}$$

Observamos que podemos expresar $D(\alpha^*, \omega^*, \beta_l^*, \beta_u^*, \lambda; \mathbf{z})$ de la forma:

$$\begin{aligned}
 D(\alpha^*, \omega^*, \beta_l^*, \beta_u^*, \lambda; \mathbf{z}) &= -\frac{1}{2} \alpha^T \alpha + \mathbf{y}^T \alpha + \beta_l^T \mathbf{1} - \beta_u^T \mathbf{u} + \lambda - \frac{\gamma}{2} \sum_i z_i (\omega_i^*)^2 \\
 &\quad + \frac{\gamma}{2} \sum_i z_i^* (\omega_i^*)^2 - \frac{\gamma}{2} \sum_i z_i^* (\omega_i^*)^2 \\
 &= -\frac{1}{2} \alpha^T \alpha + \mathbf{y}^T \alpha + \beta_l^T \mathbf{1} - \beta_u^T \mathbf{u} + \lambda - \frac{\gamma}{2} \sum_i z_i^* (\omega_i^*)^2 \\
 &\quad \underbrace{\hspace{10em}}_{D(\alpha^*, \omega^*, \beta_l^*, \beta_u^*, \lambda; \mathbf{z}^*)} \\
 &\quad + \frac{\gamma}{2} \sum_i z_i^* (\omega_i^*)^2 - \frac{\gamma}{2} \sum_i z_i (\omega_i^*)^2 \\
 &= f(\mathbf{z}^*) + \frac{\gamma}{2} (\omega^*)^2 \cdot (\mathbf{z}^* - \mathbf{z}) = f(\mathbf{z}^*) - \frac{\gamma}{2} (\omega^*)^2 \cdot (\mathbf{z} - \mathbf{z}^*).
 \end{aligned}$$

Por tanto, concluimos que

$$f(\mathbf{z}) \geq f(\mathbf{z}^*) - \frac{\gamma}{2} (\omega^*)^2 \cdot (\mathbf{z} - \mathbf{z}^*) \quad \forall \mathbf{z} \in \mathcal{Z}_k^n.$$

□

1.2.3. Algoritmo de aproximación exterior

Ya tenemos todas las herramientas que vamos a necesitar para plantear el algoritmo de aproximación exterior. Como $f(\mathbf{z})$ es convexa en $\mathbf{z}$, vamos a minimizar y refinar iterativamente un subestimador lineal a trozos de $f(\mathbf{z})$. Esta estrategia se llama Aproximación Exterior y fue planteado por primera vez por Duran y Grossmann [8]. La aproximación exterior funciona de la siguiente manera. En cada iteración t tenemos acceso a $f(\mathbf{z}_i)$ y a un conjunto de subgradiientes $\mathbf{g}_{\mathbf{z}_i}$ en los puntos $\mathbf{z}_i$ con $i \in \{1, \dots, t\}$. Construimos el siguiente subestimador:

$$f_t(\mathbf{z}) = \max_{1 \leq i \leq t} f(\mathbf{z}_i) + \mathbf{g}_{\mathbf{z}_i}^T (\mathbf{z} - \mathbf{z}_i).$$

Minimizando recursivamente $f_t(\mathbf{z})$ sobre $\mathcal{Z}_n^k$ para obtener $\mathbf{z}_t$ y evaluando $f(\cdot)$ y sus subgradiientes en $\mathbf{z}_t$, obtenemos una secuencia no decreciente de subestimadores $f_t(\mathbf{z}_t)$ que converge al valor óptimo $f(\mathbf{z})$ en un número finito de iteraciones. Esto ocurre por ser $\mathcal{Z}_n^k$ un conjunto finito y porque el algoritmo de aproximación exterior no devuelve el mismo punto dos veces. Observamos, además, que al evaluar $f(\tilde{\mathbf{z}})$ obtenemos un subestimador $\mathbf{g}_{\tilde{\mathbf{z}}}$ sin coste adicional. Formalizamos esta idea en el Algoritmo 1.

Algoritmo 1: Método de aproximación exterior para el Problema ($\mathcal{P}_{MV}^k$)

Entrada: Solución inicial $\mathbf{z}_1$

$t \leftarrow 1$

Repetir

Calcular $\mathbf{z}_{t+1}, \theta_{t+1}$ solución de

$$\begin{aligned} & \min_{\mathbf{z} \in \mathcal{Z}_k^n, \theta} \theta \\ & s.a. \quad \theta \geq f(\mathbf{z}_i) + \mathbf{g}_{\mathbf{z}_i}^T(\mathbf{z} - \mathbf{z}_i) \quad \forall i \in [t], \end{aligned}$$

Calcular $f(\mathbf{z}_{t+1})$ y $\mathbf{g}_{\mathbf{z}_{t+1}} \in \partial f(\mathbf{z}_{t+1})$

$t \leftarrow t + 1$

Hasta $f(\mathbf{z}_t) - \theta_t \leq \varepsilon$;

Salida: $\mathbf{z}_t$

El algoritmo converge en $\binom{n}{k} \leq \left(\frac{e \cdot n}{k}\right)^k$ iteraciones en el peor de los casos y en la práctica converge en menos iteraciones.

Capítulo 2

Complejidad computacional

En este capítulo vamos a estudiar la complejidad computacional del problema Media-Varianza con restricciones de cardinalidad y desigualdades lineales ($\mathcal{P}_{MV}^k$).

2.1. Introducción a la complejidad computacional

A lo largo de este capítulo vamos a trabajar con conceptos de complejidad computacional. En esta sección vamos a desarrollar brevemente aquellos conceptos que vamos a necesitar. Para ello vamos a seguir el libro “Computers and Intractability” de Michael R. Garey y David S. Johnson [11].

2.1.1. Problemas de decisión y clases de complejidad

Para empezar, vamos a definir el tipo de problemas con los que vamos a trabajar para posteriormente introducir las distintas clases que existen en función de la complejidad computacional.

Definición 2.1.1 (Problemas de decisión). *Un problema de decisión es un problema en el que su solución es Sí o No.*

Vamos a definir ahora dos clases de problemas de decisión.

Definición 2.1.2 (Problema P). *Un problema de decisión se dice que es de clase P si puede ser resuelto en tiempo polinomial.*

Definición 2.1.3 (Problema NP). *Un problema de decisión se dice que es de clase NP si una solución puede ser comprobada en tiempo polinomial.*

Ahora vamos a introducir una clase de complejidad distinta. Los problemas NP-Duros. Es importante notar que no necesariamente tienen que ser problemas de decisión.

Definición 2.1.4 (Problema NP-Duro). *Un problema P se dice NP-Duro si la existencia de un algoritmo en tiempo polinomial para P implicaría la existencia de un algoritmo en tiempo polinomial para cada problema NP. De forma equivalente se puede expresar como:*

P es NP-Duro $\iff$ Si P puede ser resuelto en tiempo polinomial, entonces $P = NP$

Finalmente, introducimos la clase de problemas NP-Completos.

Definición 2.1.5 (Problema NP-Completo). *Un problema de decisión se dice NP-Completo si es NP y NP-Duro.*




Figura 2.1: Clases de complejidad computacional

A lo largo de las siguientes secciones definiremos dos problemas que demostraremos que son NP-Duros mediante la técnica de reducción. Usaremos un problema NP-Duro conocido y demostraremos que toda instancia de este puede ser convertida en tiempo polinomial en una instancia del problema que queremos demostrar que es NP-Duro, de tal manera que la instancia original tiene solución si, y solo si, la instancia transformada también tiene solución. Para ello haremos uso del siguiente resultado de la teoría de complejidad computacional:

Teorema 2.1.1 (Teorema de reducción polinomial). *Si un problema A es NP-Duro y existe una reducción polinomial $A \leq_p B$, entonces B es también NP-Duro.*

Demostración. Véase en [18].

□

2.2. Complejidad computacional con desigualdades lineales

En esta sección, vamos a tratar la complejidad computacional del problema Media-Varianza con restricciones de cardinalidad y desigualdades lineales ($\mathcal{P}_{MV}^k$). A lo largo

de esta sección vamos a seguir el artículo “Computational study of a family of mixed-integer quadratic programming problems” de Daniel Bienstock [5].

Consideramos una clase más general, los problemas de Programación Cuadrática Entera-Mixta (QMIP):

$$\begin{aligned} & \text{mín } \mathbf{x}^T \mathbf{Q} \mathbf{x} + \mathbf{c}^T \mathbf{x} \\ \text{s.a. } & (1) \quad \mathbf{A} \mathbf{x} \leq \mathbf{b}, \\ & (2) \quad \|\mathbf{x}\|_0 \leq k, \\ & (3) \quad 0 \leq x_j \leq u_j, \quad \forall j = 1, \dots, n \end{aligned} \quad (\mathcal{P}_{QMIP})$$

con $\mathbf{x} \in \mathbb{R}^n$, $\mathbf{Q}$ una matriz simétrica y semidefinida positiva, y $k \in \mathbb{Z}_+$.

El problema puede parecer sencillo; sin embargo, vamos a demostrar que una selección de restricciones aparentemente simple, puede llevarnos a que sólo demostrar la viabilidad de las restricciones ya tenga complejidad NP-Dura.

Consideremos el conjunto de restricciones de la forma:

$$\begin{aligned} (3) \quad & \mathbf{A} \mathbf{x} \geq \mathbf{b}, \\ (4) \quad & \|\mathbf{x}\|_0 \leq k, \\ (5) \quad & 0 \leq x_j \leq 1, \quad \forall j = 1, \dots, n \end{aligned} \quad (\mathbf{Q})$$

de tal manera que una de las restricciones de (3) sea $\sum_{j=1}^n x_j \geq k$. Teniendo en cuenta que $\|\mathbf{x}\|_0 \leq k$ y $0 \leq x_j \leq 1$ tenemos que $\sum_{j=1}^n x_j \leq k$ por tanto concluimos que $\sum_{j=1}^n x_j = k$. Para que esto sea posible, se ha de cumplir, además, que $x \in \{0, 1\}^n$.

Antes de comenzar la demostración, es necesario introducir una clase de problemas NP-Duros. Demostraremos que comprobar la viabilidad de (Q) es NP-Duro reescribiendo un problema de partición en la forma de (Q).

Definición 2.2.1 (Problema de partición balanceada). *Se define como el problema de partición balanceada al siguiente problema:*

Dados $2n$ enteros $\{a_1, \dots, a_{2n}\}$ buscar una partición en dos subconjuntos de n elementos tal que ambos tengan la misma suma.

Proposición 2.2.1. *El problema de partición balanceada es NP-Completo.*

Demostración. Véase en [11]. □

Teorema 2.2.1. *Comprobar la viabilidad de (Q) es NP-Completo incluso si A tiene 3 filas.*

Demostración. Consideremos el problema de partición:

Dados $2n$ enteros $\{a_1, \dots, a_{2n}\}$ buscar una partición en dos subconjuntos de n elementos tal que ambos tengan la misma suma.

Sabemos que este problema es NP-Completo. Podemos formular dicho problema de la siguiente forma:

Consideramos las variables $x_i = \begin{cases} 1 & \text{si } a_i \text{ pertenece al primer subconjunto} \\ 0 & \text{en c.c.} \end{cases}$

Entonces el problema queda: Buscar $x \in \{0, 1\}^{2n}$ satisfaciendo:

$$\sum_{j=1}^{2n} x_j = n \quad (\text{Solo escogemos } n \text{ variables})$$

$$\sum_{j=1}^{2n} a_j x_j = S \quad (\text{Cada subconjunto debe sumar } S)$$

$$S = \frac{1}{2} \sum_{j=1}^{2n} a_j$$

Podemos reescribir dicho problema en la forma de (Q). Para ello lo reformulamos de la siguiente manera:

Buscar $x \in \{0, 1\}^{2n}$ satisfaciendo:

$$\begin{aligned} \sum_{j=1}^{2n} x_j &\leq n \\ \sum_{j=1}^{2n} x_j &\geq n \\ \sum_{j=1}^{2n} a_j x_j &\leq S \\ \sum_{j=1}^{2n} a_j x_j &\geq S \end{aligned}$$

Si tomamos $k = n$ tenemos que $\sum_{j=1}^{2n} x_j \leq n \implies \|\mathbf{x}\|_0 \leq n = k$. Tomando las tres primeras desigualdades en formato matricial llegamos a:

$$\begin{bmatrix} a_1 & \cdots & a_{2n} \\ -a_1 & \cdots & -a_{2n} \\ 1 & \cdots & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ \vdots \\ x_{2n} \end{bmatrix} \leq \begin{bmatrix} S \\ -S \\ n \end{bmatrix}.$$

Finalmente, como tenemos $x \in \{0, 1\}^{2n}$, se cumple $0 \leq x_j \leq 1 \quad \forall j = 1, \dots, 2n$. Llegando así a las desigualdades de (Q). $\square$

2.3. Complejidad computacional sin desigualdades lineales

En esta sección vamos a estudiar la complejidad computacional del problema Media-Varianza con restricciones de cardinalidad sin desigualdades lineales ($\mathcal{P}_{cmv}(\mathbf{D}, \mathbf{r}, \hat{r})$). Vamos a seguir el artículo “Optimal Cardinality Constrained Portfolio Selection” de Jianjun Gao y Duan Li [10].

Consideramos la siguiente formulación del problema Media-Varianza con restricciones de cardinalidad sin desigualdades lineales:

$$\begin{aligned} \min_{\mathbf{x} \in \mathbb{R}^n} \quad & \frac{1}{2} \mathbf{x}^T \mathbf{D} \mathbf{x} \\ \text{s.a.} \quad & \mathbf{r}^T \mathbf{x} = \bar{r}, \\ & \mathbf{e}^T \mathbf{x} = 1 \\ & \|\mathbf{x}\|_0 \leq s \end{aligned} \quad (\mathcal{P}_{cmv}(\mathbf{D}, \mathbf{r}, \hat{r}))$$

Vamos a demostrar que ($\mathcal{P}_{cmv}(\mathbf{D}, \mathbf{r}, \hat{r})$) es NP-Duro incluso sin las desigualdades lineales¹. Comenzamos demostrando que el siguiente problema particular de optimización con restricciones de cardinalidad pura ($\mathcal{P}_1$) es NP-Duro.

$$\begin{aligned} \min_{\mathbf{x} \in \mathbb{R}^n} \quad & \frac{1}{2} \mathbf{x}^T \mathbf{Q} \mathbf{x} - \mathbf{e}^T \mathbf{x} \\ \text{s.a.} \quad & \|\mathbf{x}\|_0 \leq s \end{aligned} \quad (\mathcal{P}_1)$$

con $\mathbf{Q}$ es una matriz definida positiva. Para ello, introducimos el siguiente problema NP-Duro.

Definición 2.3.1 (Problema Suma de vectores de un subconjunto de tamaño k).

Dados $X := \{\mathbf{A}_1, \dots, \mathbf{A}_n\}$ conjunto de vectores con $\mathbf{A}_i \in \mathbb{Z}^m$, $m < n$, un entero s y un vector $\mathbf{B} \in \mathbb{Z}^m$ se define el problema de suma de vectores de un subconjunto de tamaño k como:

Buscar $\{\hat{\mathbf{A}}_1, \dots, \hat{\mathbf{A}}_s\} \subset X$ con $\sum_{i=1}^s \hat{\mathbf{A}}_i = \mathbf{B}$.

Proposición 2.3.1. El problema de suma de vectores de un subconjunto de tamaño k es NP-Duro.

Demostración. El resultado está probado por el Teorema 3.2 en Fellows y Koblitz [9] y Garey y Johnson [11]. $\square$

¹Aunque el problema ($\mathcal{P}_{MV}^{k,\gamma}$) es más manejable que el problema ($\mathcal{P}_{cmv}(\mathbf{D}, \mathbf{r}, \hat{r})$), ambos son NP-Duros. Aunque no se va a demostrar explícitamente que ($\mathcal{P}_{MV}^{k,\gamma}$) es NP-Duro se deduce inmediatamente de el hecho de que ($\mathcal{P}_{cmv}(\mathbf{D}, \mathbf{r}, \hat{r})$) es NP-Duro. Consultar [3]

Corolario 2.3.1. *El problema de suma de vectores de un subconjunto de tamaño k con $\mathbf{B} = \mathbf{0}$ es NP-Duro.*

Demostración. Véase en [10]. □

Proposición 2.3.2. *El Problema $(\mathcal{P}_1)$ es NP-Duro.*

Demostración.

Vamos a mostrar que el Problema de suma de vectores de un subconjunto de tamaño k y $\mathbf{B} = \mathbf{0}$ puede ser reducido al problema $(\mathcal{P}_1)$.

Consideremos entonces una instancia del problema con $\{A_1, \dots, A_n\} \subset \mathbb{Z}^n$, $0 < s < n$, $s \in \mathbb{Z}_+$, $A_i \in \mathbb{Z}^m$, $m < n$ y $B = 0$ y definimos $\mathbf{H} := (\mathbf{A}_1, \dots, \mathbf{A}_n)$. Sea $\mathbf{z} = (z_1, \dots, z_n)^T$ el vector formado por las variables de decisión. Entonces resolver el problema es equivalente a resolver:

$$\begin{aligned} \text{Buscar } & \mathbf{z} \in \{0, 1\}^n \\ \text{s.a. } & \mathbf{H}\mathbf{z} = \mathbf{0}, \\ & \mathbf{e}^T \mathbf{z} = s \end{aligned} \quad (\mathcal{P}_2)$$

Consideremos ahora el siguiente problema:

$$\begin{aligned} \min_{\mathbf{x} \in \mathbb{R}^n} \quad & \hat{f} := \frac{1}{2} \|\mathbf{x} - \mathbf{e}\|^2 + \|\mathbf{H}\mathbf{x}\|^2 \\ \text{s.a. } & \|\mathbf{x}\|_0 \leq s \end{aligned} \quad (\mathcal{G})$$

Tenemos que $(\mathcal{G})$ es un caso especial de $(\mathcal{P}_1)$.

Consideramos, además, los siguientes subproblemas:

$$\begin{aligned} \min_{\mathbf{x} \in \mathbb{R}^n} \quad & f_1(\mathbf{x}) = \frac{1}{2} \|\mathbf{x} - \mathbf{e}\|^2 \\ \text{s.a. } & \|\mathbf{x}\|_0 \leq s \end{aligned} \quad (\mathcal{G}_1)$$

$$\begin{aligned} \min_{\mathbf{x} \in \mathbb{R}^n} \quad & f_2(\mathbf{x}) = \|\mathbf{H}\mathbf{x}\|^2 \\ \text{s.a. } & \|\mathbf{x}\|_0 \leq s \end{aligned} \quad (\mathcal{G}_2)$$

Denotamos $v(\cdot)$ como el valor óptimo objetivo del problema. Tenemos $v(\mathcal{G}) \geq v(\mathcal{G}_1) + v(\mathcal{G}_2)$.

Desarrollando la expresión de f_1 tenemos:

$$f_1(\mathbf{x}) = \frac{1}{2} \|\mathbf{x} - \mathbf{e}\|^2 = \frac{1}{2} [(x_1 - 1)^2 + \dots + (x_n - 1)^2].$$

La restricción $\|\mathbf{x}\|_0 \leq s$ implica que $\mathbf{x}$ tiene a lo sumo s componentes no nulas. Teniendo en cuenta la expresión de f_1 , tenemos:

$$f_1(\mathbf{x}) = \frac{1}{2} [(\hat{x}_1 - 1)^2 + \dots + (\hat{x}_p - 1)^2 + \sum_{i=1}^{n-p} (-1)^2],$$

donde $\hat{x}_1, \dots, \hat{x}_p$ denotan las p variables no nulas. Podemos observar que el mínimo de f_1 se alcanza cuando $p = s$ y $\hat{x}_1 = \dots = \hat{x}_s = 1$, quedando:

$$v(\mathcal{G}_1) = f_1(\mathbf{x}) = \frac{1}{2} \sum_{i=1}^{n-s} (-1)^2 = \frac{1}{2}(n-s)$$

Por otra parte, para el problema $(\mathcal{G}_2)$ tenemos $v(\mathcal{G}_2) \geq 0$. En particular, $v(\mathcal{G}_2) = 0$ si existe $\hat{\mathbf{x}}$ satisfaciendo $\mathbf{H}\hat{\mathbf{x}} = \mathbf{0}$ con $\|\hat{\mathbf{x}}\|_0 \leq s$. Por tanto, tenemos $v(\mathcal{G}) \geq \frac{1}{2}(n-s)$. Si tenemos $v(\mathcal{G}) = \frac{1}{2}(n-s)$ entonces la solución óptima de $(\mathcal{G}_2)$, x^* satisface $x_i^* \in \{0, 1\}^n$ para $i = 1, \dots, n$, $\sum_{i=1}^n x_i^* = s$ y $Hx^* = 0$ lo que implica que x^* es solución de $(\mathcal{P}_2)$. Por otra parte si tenemos que $v(\mathcal{G}) > \frac{1}{2}(n-s)$, entonces no existe x^* satisfaciendo $x \in \{0, 1\}^n$, $\sum_{i=1}^n x_i^* = s$ y $\mathbf{H}\mathbf{x} = \mathbf{0}$ lo que implica que el problema $(\mathcal{P}_2)$ no tiene solución. De esta manera, concluimos que cualquier instancia de $(\mathcal{P}_2)$ puede ser reformulado como una instancia de $(\mathcal{P}_1)$. Esto implica que el problema $(\mathcal{P}_1)$ es NP-Duro por la regla de reducción. $\square$

Observación 2. Al resolver $(\mathcal{G})$ que es una instancia de $(\mathcal{P}_1)$ obtenemos una solución de $(\mathcal{P}_2)$. Si $(\mathcal{G})$ satisface que su valor óptimo es $v(\mathcal{G}) = \frac{1}{2}(n-s)$ entonces $(\mathcal{P}_2)$ tiene solución. En caso de no satisfacerlo $(\mathcal{P}_2)$ no tiene solución.

Observación 3. Observamos que $(\mathcal{G})$ es un caso especial de $(\mathcal{P}_1)$. Basta tener en cuenta:

$$\begin{aligned} \frac{1}{2}\|x - \mathbf{e}\|^2 &= \frac{1}{2}(x - \mathbf{e})^T(x - \mathbf{e}) \\ &= \frac{1}{2}(x^T x - x^T \mathbf{e} - \mathbf{e}^T x + \mathbf{e}^T \mathbf{e}) \\ &= \frac{1}{2}x^T I x - x^T \mathbf{e} + \mathbf{e}^T \mathbf{e}. \end{aligned}$$

De igual modo, tenemos:

$$\|Hx\|^2 = (Hx)^T(Hx) = x^T H^T H x = \frac{1}{2}x^T (2H^T H)x.$$

Combinando ambas, llegamos a :

$$\frac{1}{2}\|x - \mathbf{e}\|^2 + \|Hx\|^2 = \frac{1}{2}x^T \underbrace{(I + 2H^T H)}_Q x - \mathbf{e}^T x + \underbrace{\mathbf{e}^T \mathbf{e}}_{\text{Constante}}, \quad (2.1)$$

con $Q = I + 2H^T H$ matriz definida positiva, pues I es definida positiva y $H^T H$ es semidefinida positiva ($x^T H^T H x = (Hx)^T (Hx) = \|Hx\|^2 \geq 0$).

Observamos que (2.1) es nuestro problema ($\mathcal{G}$) más una constante. Al tratarse de un problema de minimización, podemos afirmar que es el mismo problema.

Definimos ahora una serie de problemas de optimización para posteriormente demostrar que son problemas equivalente entre sí y equivalentes a ($\mathcal{P}_1$). Finalmente, demostraremos que nuestro problema ($\mathcal{P}_{ccmv}(\mathbf{D}, \mathbf{r}, \hat{r})$) es equivalente a estos y, por tanto, NP-Duro.

Definición 2.3.2 (Problema CCQO). *Definimos el problema de optimización cuadrático puro con restricciones de cardinalidad*

$$\begin{aligned} \min_{\mathbf{x} \in \mathbb{R}^n} \quad & \frac{1}{2} \mathbf{x}^T \mathbf{D} \mathbf{x} + \mathbf{d}^T \mathbf{x} + \mathbf{c} \\ \text{s.a.} \quad & \|\mathbf{x}\|_0 \leq s \end{aligned} \quad (\mathcal{P}_{ccqo}^p(\mathbf{D}, \mathbf{d}, \mathbf{c}))$$

Definición 2.3.3 (Problema CC-Minvar). *Definimos el problema de varianza mínima global con restricción de cardinalidad*

$$\begin{aligned} \min_{\mathbf{x} \in \mathbb{R}^n} \quad & \frac{1}{2} \mathbf{x}^T \mathbf{D} \mathbf{x} \\ \text{s.a.} \quad & \|\mathbf{x}\|_0 \leq s \\ & \mathbf{e}^T \mathbf{x} = 1. \end{aligned} \quad (\mathcal{P}_{cc-minvar}(\mathbf{D}))$$

Lema 2.3.1. *Resolver ($\mathcal{P}_{ccqo}^p(\mathbf{D}, \mathbf{d}, \mathbf{c})$) es equivalente a resolver ($\mathcal{P}_{cc-minvar}(\mathbf{D})$).*

Demostración. Denotamos la dispersión como $\mathbf{z} = (z_1, \dots, z_n)^T \in \mathbb{Z}(s)$. Consideremos el problema $\mathcal{P}_{ccqo}^p$ con $\mathbf{z} \in \mathbb{Z}(s)$ fijo:

$$\min_{\mathbf{x} \in \mathbb{R}^n} \quad \frac{1}{2} (\mathbf{Z} \mathbf{x})^T (\mathbf{Z} \mathbf{D} \mathbf{Z}) (\mathbf{Z} \mathbf{x}) + (\mathbf{Z} \mathbf{d})^T (\mathbf{Z} \mathbf{x}) \quad (\mathcal{P}_{ccqo}^p(\mathbf{z}))$$

con $\mathbf{Z} = \text{diag}(z_1, \dots, z_n)$. Tenemos que $\mathbf{D} \succ \mathbf{0}$, por tanto $\mathbf{Z} \mathbf{D} \mathbf{Z} \succeq \mathbf{0}$. Al tener $\mathbf{z}$ fijo, podemos calcular la solución del problema. Si llamamos $f_{ccqo}(\mathbf{x}) = \frac{1}{2} (\mathbf{Z} \mathbf{x})^T (\mathbf{Z} \mathbf{D} \mathbf{Z}) (\mathbf{Z} \mathbf{x}) + (\mathbf{Z} \mathbf{d})^T (\mathbf{Z} \mathbf{x})$, tenemos $\nabla f_{ccqo}(\mathbf{x}) = (\mathbf{Z} \mathbf{D} \mathbf{Z}) \mathbf{x} + \mathbf{Z} \mathbf{d}$ y $\nabla^2 f_{ccqo}(\mathbf{x}) = \mathbf{Z} \mathbf{D} \mathbf{Z} \succeq \mathbf{0}$. Por tanto, tenemos que $\mathbf{x}^*$ satisfaciendo $\mathbf{Z} \mathbf{D} \mathbf{Z} \mathbf{x}^* = -\mathbf{Z} \mathbf{d}$ es mínimo global.

Tenemos que $\mathbf{Z} \mathbf{D} \mathbf{Z}$ tiene la siguiente forma:

$$\mathbf{Z} \mathbf{D} \mathbf{Z} = \begin{pmatrix} z_1^2 d_{11} & z_1 z_2 d_{12} & \cdots & z_1 z_n d_{1n} \\ z_2 z_1 d_{21} & z_2^2 d_{22} & \cdots & z_2 z_n d_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ z_n z_1 d_{n1} & z_n z_2 d_{n2} & \cdots & z_n^2 d_{nn} \end{pmatrix}.$$

Basta con que $s < n$, es decir, que $z_i = 0$ para algún i , para obtener una columna de ceros. Por tanto, podemos decir que en general no es invertible.

Consideramos $\mathbf{x}^* = -(\mathbf{ZDZ})^\dagger(\mathbf{Zd})$. Tenemos que $\mathbf{x}^*$ cumple:

$$\begin{aligned}\nabla f_{ccqo}(\mathbf{x}^*) &= \mathbf{ZDZ}(-(\mathbf{ZDZ})^\dagger(\mathbf{Zd})) + \mathbf{Zd} = [-\mathbf{ZDZ}(\mathbf{ZDZ})^\dagger]\mathbf{Zd} + \mathbf{Zd} \\ &= (\mathbf{I} - (\mathbf{ZDZ})(\mathbf{ZDZ})^\dagger)\mathbf{Zd}\end{aligned}$$

con $\mathbf{ZDZ}(\mathbf{ZDZ})^\dagger\mathbf{Zd} = \mathbf{Zd}$.

Es decir, $\mathbf{x}^*$ verifica $\nabla f_{ccqo}(\mathbf{x}^*) = \mathbf{0}$ y además es el vector que lo satisface con mínima norma. Esto último garantiza que aquellas x_i tal que $z_i = 0$ satisfacen $x_i = 0$.

Tenemos que $v(\mathcal{P}_{ccqo}^p) = -\frac{1}{2}(\mathbf{Zd})^T(\mathbf{ZDZ})^\dagger(\mathbf{Zd})$.

Consideramos ahora el problema $\mathcal{P}_{cc-minvar}$ con $\mathbf{z} \in \mathcal{Z}(s)$ fijo.

$$\min_{\mathbf{x} \in \mathbb{R}^n} \frac{1}{2}(\mathbf{Zx})^T(\mathbf{ZDZ})(\mathbf{Zx}) \mid \mathbf{e}^T(\mathbf{Zx}) = 1 \quad (\mathcal{P}_{cc-minvar}(\mathbf{z}))$$

Tenemos $\mathcal{L}(\mathbf{x}, \lambda) = \frac{1}{2}(\mathbf{Zx})^T(\mathbf{ZDZ})(\mathbf{Zx}) - \lambda(\mathbf{e}^T\mathbf{Zx} - 1)$ con gradiente respecto a $\mathbf{x}$: $\nabla_{\mathbf{x}}\mathcal{L}(\mathbf{x}, \lambda) = \mathbf{ZDZx} - \lambda\mathbf{Ze}$. Igualando a cero llegamos a $\mathbf{ZDZx} = \lambda\mathbf{Ze}$. Tomamos nuevamente $\mathbf{x}^*(\lambda) = \lambda(\mathbf{ZDZ})^\dagger\mathbf{Ze}$. Determinamos ahora λ utilizando la restricción $\mathbf{1}^T\mathbf{Zx}^* = \mathbf{1}^T\mathbf{Z}(\lambda(\mathbf{ZDZ})^\dagger\mathbf{Ze}) = 1$. Es decir, $\lambda(\mathbf{z}) = \frac{1}{(\mathbf{Ze})^T(\mathbf{ZDZ})^\dagger(\mathbf{Ze})}$.

Obtenemos así $\mathbf{x}_{cc-minvar}(\mathbf{z}) = \lambda(\mathbf{z})(\mathbf{ZDZ})^\dagger(\mathbf{Ze})$ con $\lambda(\mathbf{z}) = \frac{1}{(\mathbf{Ze})^T(\mathbf{ZDZ})^\dagger(\mathbf{Ze})}$

con valor objetivo $v(\mathcal{P}_{cc-minvar}) = \frac{1}{2} \frac{1}{(\mathbf{Ze})^T(\mathbf{ZDZ})^\dagger(\mathbf{Ze})}$.

Para finalizar, consideramos ahora el problema $\mathcal{P}_{ccqo}^p$ con $\mathbf{d} = -\mathbf{e}$ y buscamos la dispersión que minimice el problema:

$$\begin{aligned}\mathbf{z}_{ccqo}^* &= \arg \min_{\mathbf{z} \in \mathcal{Z}} (\mathcal{P}_{ccqo}^p(\mathbf{z})) \\ &= \arg \min_{\mathbf{z} \in \mathcal{Z}} \left(-\frac{1}{2}(\mathbf{Ze})^T(\mathbf{ZDZ})^\dagger\mathbf{Ze} \right) \\ &= \arg \max_{\mathbf{z} \in \mathcal{Z}} ((\mathbf{Ze})^T(\mathbf{ZDZ})^\dagger\mathbf{Ze}) \\ &= \arg \min_{\mathbf{z} \in \mathcal{Z}} \left(\frac{1}{(\mathbf{Ze})^T(\mathbf{ZDZ})^\dagger\mathbf{Ze}} \right) \\ &= \mathbf{z}_{cc-minvar}^*.\end{aligned}$$

Observamos así que la dispersión óptima $\mathbf{z}^*$ del problema $(\mathcal{P}_{ccqo}^p(\mathbf{D}, \mathbf{d}, \mathbf{c}))$ con $\mathbf{d} = -\mathbf{e}$ es también la dispersión óptima del problema $(\mathcal{P}_{cc-minvar}(\mathbf{D}))$. □

Observación 4. En la demostración anterior hemos afirmado la siguiente igualdad:

$$\mathbf{ZDZ}(\mathbf{ZDZ})^\dagger\mathbf{Zd} = \mathbf{Zd}.$$

Para ello, hemos usado el siguiente resultado.

Teorema 2.3.1. Supongamos $\mathbf{A} \in \mathbb{R}^{m \times n}$, $\mathbf{b} \in \mathbb{R}^m$. Entonces $\mathbf{A}\mathbf{A}^\dagger\mathbf{b} = \mathbf{b}$ si y sólo si $\mathbf{b} \in \text{Col}(\mathbf{A})$.

Demostración. Véase en [13]. □

Lema 2.3.2. $\mathbf{Zd} \in \text{Col}(\mathbf{ZDZ})$.

Demostración. Tenemos que $\mathbf{D} \succ \mathbf{0}$. Consideramos la submatriz de $\mathbf{ZDZ}$ resultante de eliminar las filas y columnas correspondientes a los $z_i = 0$. Tenemos que la matriz resultante es una submatriz de $\mathbf{D}$ y, por tanto, es definida positiva. Tenemos entonces que $\mathbf{ZDZ} \Big|_{i: z_i \neq 0, j: z_j \neq 0}$ es invertible. De igual forma, consideramos $\mathbf{Zd} \Big|_{i: z_i \neq 0}$. Tenemos que están ajustadas para la multiplicación, por tanto podemos afirmar que existe un único $\mathbf{x}^*$ tal que $\mathbf{ZDZ} \Big|_{i,j: z_i \neq 0, z_j \neq 0} \mathbf{x}^* = \mathbf{Zd} \Big|_{i: z_i \neq 0}$. Basta considerar $\hat{\mathbf{x}}^*$ con

$$\hat{x}_i = \begin{cases} x_i & \text{si } z_i \neq 0 \\ 0 & \text{si } z_i = 0 \end{cases}$$

tenemos $\mathbf{ZDZ}\mathbf{x}^* = \mathbf{Zd}$ y por tanto $\mathbf{Zd} \in \text{Col}(\mathbf{ZDZ})$ como queríamos probar. □

Observación 5. En la demostración del Lema (2.3.1) hemos utilizado un resultado sobre la Pseudoinversa de Penrose que se enuncia a continuación.

Teorema 2.3.2. Sea $\mathbf{A} \in \mathbb{R}^{m \times n}$, $\mathbf{b} \in \mathbb{R}$. Entonces $\mathbf{x} = \mathbf{A}^\dagger\mathbf{b}$ es la solución de

$$\min_{\mathbf{x} \in \mathbb{R}^n} \|\mathbf{Ax} - \mathbf{b}\|_2^2$$

con mínima norma.

Demostración. Véase en [1]. □

Corolario 2.3.2 (Resolver $(\mathcal{P}_1)$ es equivalente a resolver $(\mathcal{P}_{cc-\minvar}(\mathbf{D}))$).

Demostración. Tenemos que $(\mathcal{P}_1)$ es $(\mathcal{P}_{ccqo}^p(\mathbf{D}, \mathbf{d}, \mathbf{c}))$ con $\mathbf{D} = \mathbf{Q}$, $\mathbf{d} = -\mathbf{e}$, $\mathbf{c} = \mathbf{0}$. □

Proposición 2.3.3. Resolver $\mathcal{P}_{cc-\minvar}$ es equivalente a resolver $\mathcal{P}_{ccmv}$.

Demostración. Basta considerar $(\mathcal{P}_{ccmv}(\mathbf{D}, \mathbf{r}, \hat{\mathbf{r}}))$ con $\mathbf{r}$ y $\hat{\mathbf{r}}$ tales que la restricción $\mathbf{r}^T\mathbf{x} = \hat{\mathbf{r}}$ sea linealmente dependiente de $\mathbf{e}^T\mathbf{x} = 1$ y, por tanto, redundante. □

Teorema 2.3.3. El problema $(\mathcal{P}_{ccmv}(\mathbf{D}, \mathbf{r}, \hat{\mathbf{r}}))$ es NP-Duro.

Demostración. Tenemos que el problema $(\mathcal{P}_1)$ es NP-Duro. Hemos demostrado que resolver $(\mathcal{P}_1)$ es equivalente a resolver $(\mathcal{P}_{cc-\minvar}(\mathbf{D}))$. Además, hemos demostrado que $(\mathcal{P}_{cc-\minvar}(\mathbf{D}))$ es una instancia de $(\mathcal{P}_{ccmv}(\mathbf{D}, \mathbf{r}, \hat{\mathbf{r}}))$. De esta forma, concluimos que toda instancia de $(\mathcal{P}_1)$ puede ser reformulada como una instancia de $(\mathcal{P}_{ccmv}(\mathbf{D}, \mathbf{r}, \hat{\mathbf{r}}))$ con lo que concluimos que $(\mathcal{P}_{ccmv}(\mathbf{D}, \mathbf{r}, \hat{\mathbf{r}}))$ es NP-Duro por la regla de reducción. □

Capítulo 3

Análisis de sensibilidad

En este capítulo vamos a estudiar la dependencia del problema $(\mathcal{P}_{MV}^{k,\gamma})$ respecto del parámetro de regularización γ . Este es un problema importante en la práctica porque realmente estamos interesados en resolver el problema $(\mathcal{P}_{MV}^k)$. Podemos resolver el problema con término de regularización $(\mathcal{P}_{MV}^{k,\gamma})$ para obtener un vector soporte $\mathbf{z}$ para posteriormente resolver el problema sin término de regularización $(\mathcal{P}_{MV}^k)$ con $\mathbf{z}$ fijo. Esto último puede ser resuelto por *solvers* comerciales de manera muy eficiente. Por tanto, nos queda resolver la duda de qué tan subóptima es la solución $\mathbf{z}^*$ óptima del problema $(\mathcal{P}_{MV}^{k,\gamma})$. A lo largo de esta sección vamos a seguir de cerca el artículo “A Scalable Algorithm for Sparse Portfolio Selection” de D. Bertsimas y R. Cory-Wright [3] y vamos a usar resultados de análisis de sensibilidad del libro “Introduction to linear optimization” de D. Bertsimas y J. Tsitsiklis [4].

En primer lugar, vamos a ver que el vector de soporte óptimo $\mathbf{z}$ para un problema con un valor de regularización γ alto puede servir como punto inicial de alta calidad para resolver un problema con menor regularización.

Proposición 3.0.1. *Sea $k \leq n$ un presupuesto de cardinalidad fijo. Sea $\mathbf{z}^*(\gamma)$ una solución óptima para el problema $(\mathcal{P}_1)$ para γ fijo, sea $f_\gamma(\mathbf{z})$ el valor objetivo óptimo del problema $(\mathcal{P}_2)$ para γ fijo. Entonces, para cualquier $\Delta > 0$:*

$$0 \leq f_{\gamma+\Delta}(\mathbf{z}^*(\gamma)) - f_{\gamma+\Delta}(\mathbf{z}^*(\gamma + \Delta)) \leq \frac{1}{2\gamma} - \frac{1}{2(\gamma + \Delta)}.$$

Demostración. Se tiene que $\mathbf{z}^*(\gamma + \Delta)$ es óptimo para el problema de minimización, por tanto

$$f_{\gamma+\Delta}(\mathbf{z}^*(\gamma + \Delta)) \leq f_{\gamma+\Delta}(\mathbf{z}^*(\gamma))$$

y por tanto

$$0 \leq f_{\gamma+\Delta}(\mathbf{z}^*(\gamma)) - f_{\gamma+\Delta}(\mathbf{z}^*(\gamma + \Delta)).$$

Tenemos que para $\mathbf{z}^*(\gamma)$ quedan los respectivos problemas:

$$\begin{aligned} f_\gamma(\mathbf{z}^*(\gamma)) &= \min_{\mathbf{x} \in \mathbb{R}^n} \frac{1}{2\gamma} \|\mathbf{x}\|_2^2 + \frac{1}{2} \|\mathbf{XZ}^*(\gamma)\mathbf{x} - \mathbf{y}\|_2^2 + \mathbf{d}^T \mathbf{Z}^*(\gamma)\mathbf{x} \\ \text{s.a. } &\mathbf{l} \leq \mathbf{AZ}^*(\gamma)\mathbf{x} \leq \mathbf{u} \\ &\mathbf{e}^T \mathbf{Z}^*(\gamma)\mathbf{x} = 1 \\ &\mathbf{Z}^*(\gamma)\mathbf{x} \geq 0 \end{aligned}$$

$$\begin{aligned} f_{\gamma+\Delta}(\mathbf{z}^*(\gamma)) &= \min_{\mathbf{x} \in \mathbb{R}^n} \frac{1}{2(\gamma+\Delta)} \|\mathbf{x}\|_2^2 + \frac{1}{2} \|\mathbf{XZ}^*(\gamma)\mathbf{x} - \mathbf{y}\|_2^2 + \mathbf{d}^T \mathbf{Z}^*(\gamma)\mathbf{x} \\ \text{s.a. } &\mathbf{l} \leq \mathbf{AZ}^*(\gamma)\mathbf{x} \leq \mathbf{u} \\ &\mathbf{e}^T \mathbf{Z}^*(\gamma)\mathbf{x} = 1 \\ &\mathbf{Z}^*(\gamma)\mathbf{x} \geq 0 \end{aligned}$$

Tenemos que $\forall \mathbf{x} \in \mathbb{R}^n$ factible se cumple:

$$\begin{aligned} &\frac{1}{2(\gamma+\Delta)} \|\mathbf{x}\|_2^2 + \frac{1}{2} \|\mathbf{XZ}\mathbf{x} - \mathbf{y}\|_2^2 + \mathbf{d}^T \mathbf{Z}\mathbf{x} - \left(\frac{1}{2\gamma} \|\mathbf{x}\|_2^2 + \frac{1}{2} \|\mathbf{XZ}\mathbf{x} - \mathbf{y}\|_2^2 + \mathbf{d}^T \mathbf{Z}\mathbf{x} \right) \\ &= \frac{1}{2(\gamma+\Delta)} \|\mathbf{x}\|_2^2 - \frac{1}{2\gamma} \|\mathbf{x}\|_2^2 \leq 0 \end{aligned}$$

Pues $\gamma, \Delta > 0$. Es decir, si definimos

$$\begin{aligned} h_\gamma(\mathbf{x}, \mathbf{z}) &= \frac{1}{2\gamma} \|\mathbf{x}\|_2^2 + \frac{1}{2} \|\mathbf{XZ}\mathbf{x} - \mathbf{y}\|_2^2 + \mathbf{d}^T \mathbf{Z}\mathbf{x} \\ h_{\gamma+\Delta}(\mathbf{x}, \mathbf{z}) &= \frac{1}{2(\gamma+\Delta)} \|\mathbf{x}\|_2^2 + \frac{1}{2} \|\mathbf{XZ}^*(\gamma)\mathbf{x} - \mathbf{y}\|_2^2 + \mathbf{d}^T \mathbf{Z}^*(\gamma)\mathbf{x} \end{aligned}$$

se cumple que, para $\mathbf{z} \in \mathcal{Z}_k^n$ fijo,

$$h_{\gamma+\Delta}(\mathbf{x}, \mathbf{z}) \leq h_\gamma(\mathbf{x}, \mathbf{z}) \quad \forall \mathbf{x} \text{ factible.}$$

Por tanto,

$$f_{\gamma+\Delta}(\mathbf{z}^*(\gamma)) = \min_{\mathbf{x} \in \mathbb{R}^n : \mathbf{x} \text{ factible}} h_{\gamma+\Delta}(\mathbf{x}, \mathbf{z}^*(\gamma)) \leq \min_{\mathbf{x} \in \mathbb{R}^n : \mathbf{x} \text{ factible}} h_\gamma(\mathbf{x}, \mathbf{z}^*(\gamma)) = f_\gamma(\mathbf{z}^*(\gamma)).$$

Luego tenemos que

$$f_{\gamma+\Delta}(\mathbf{z}^*(\gamma)) - f_{\gamma+\Delta}(\mathbf{z}^*(\gamma+\Delta)) \leq f_\gamma(\mathbf{z}^*(\gamma)) - f_{\gamma+\Delta}(\mathbf{z}^*(\gamma+\Delta)).$$

Tenemos, además:

$$f_\gamma(\mathbf{z}^*(\gamma)) \leq f_\gamma(\mathbf{z}^*(\gamma+\Delta))$$

por ser $\mathbf{z}^*(\gamma)$ la solución óptima para el problema con término de regularización γ .

Por tanto, llegamos a:

$$f_\gamma(\mathbf{z}^*(\gamma)) - f_{\gamma+\Delta}(\mathbf{z}^*(\gamma+\Delta)) \leq f_\gamma(\mathbf{z}^*(\gamma+\Delta)) - f_{\gamma+\Delta}(\mathbf{z}^*(\gamma+\Delta))$$

Consideramos $\mathbf{x}^*(\mathbf{z}^*(\gamma + \Delta))$, la elección óptima para $\mathbf{z}^*(\gamma + \Delta)$ en el problema con término de regularización $\gamma + \Delta$. Tenemos que $\mathbf{x}^*(\mathbf{z}^*(\gamma + \Delta))$ es factible para el problema con término de regularización γ evaluado en $\mathbf{z}^*(\gamma + \Delta)$. Esto se debe a que las restricciones dependen únicamente de $\mathbf{z}$ y no de γ . Por tanto, tenemos:

$$\begin{aligned} f_\gamma(\mathbf{z}^*(\gamma + \Delta)) &\leq \frac{1}{2\gamma} \|\mathbf{x}^*\|_2^2 + \frac{1}{2} \|\mathbf{XZx} - \mathbf{y}\|_2^2 + \mathbf{d}^T \mathbf{Zx} \\ f_{\gamma+\Delta}(\mathbf{z}^*(\gamma + \Delta)) &= \frac{1}{2\gamma} \|\mathbf{x}^*\|_2^2 + \frac{1}{2} \|\mathbf{XZx} - \mathbf{y}\|_2^2 + \mathbf{d}^T \mathbf{Zx} \end{aligned}$$

donde la desigualdad se tiene porque $\mathbf{x}^*(\mathbf{z}^*(\gamma + \Delta))$ no es necesariamente óptimo para el problema con término de regularización γ . La igualdad se tiene porque sí es una elección óptima para el problema con término $\gamma + \Delta$.

Teniendo en cuenta esto, llegamos a

$$f_\gamma(\mathbf{z}^*(\gamma + \Delta)) - f_{\gamma+\Delta}(\mathbf{z}^*(\gamma + \Delta)) \leq \left(\frac{1}{2\gamma} - \frac{1}{2(\gamma + \Delta)} \right) \|\mathbf{x}^*(\mathbf{z}^*(\gamma + \Delta))\|^2$$

Teniendo en cuenta que los $\mathbf{x}$ factibles pertenecen al simplex unidad, tenemos que

$$\left(\frac{1}{2\gamma} - \frac{1}{2(\gamma + \Delta)} \right) \|\mathbf{x}^*(\mathbf{z}^*(\gamma + \Delta))\|^2 \leq \frac{1}{2\gamma} - \frac{1}{2(\gamma + \Delta)}.$$

De esta manera, concluimos

$$0 \leq f_{\gamma+\Delta}(\mathbf{z}^*(\gamma)) - f_{\gamma+\Delta}(\mathbf{z}^*(\gamma + \Delta)) \leq \frac{1}{2\gamma} - \frac{1}{2(\gamma + \Delta)}$$

tal y como queríamos probar. $\square$

En el siguiente resultado, vamos a demostrar que, para un término de regularización γ lo suficientemente grande, es posible obtener el mismo soporte óptimo para el problema con término de regularización ($\mathcal{P}_{MV}^{k,\gamma}$) que para el problema sin término de regularización ($\mathcal{P}_{MV}^k$).

Proposición 3.0.2. *Sea $\mathbf{z}^*(\gamma)$ una solución óptima del problema ($\mathcal{P}_1$) para γ fijo, sea $f_\gamma(\mathbf{z})$ el valor objetivo óptimo del problema ($\mathcal{P}_2$) para γ fijo. Entonces, existe un parámetro $\gamma_0 > 0$ tal que para cualquier $\gamma \geq \gamma_0$, se tiene:*

$$f_\gamma(\mathbf{z}^*(\gamma_0)) = f_\gamma(\mathbf{z}^*(\gamma)).$$

Demostración. Sea $\mathbf{z} \in \mathcal{Z}_n^k$, tenemos que $f_\gamma(\mathbf{z})$ es cóncava en $\frac{1}{\gamma}$, para ello consideramos $t := \frac{1}{\gamma}$ y llegamos a:

$$f_\gamma(\mathbf{z}) = \min_{\mathbf{x} \in \mathcal{F}(\mathbf{z})} \frac{1}{2} \|\mathbf{x}\|_2^2 \cdot t + \frac{1}{2} \|\mathbf{XZx} - \mathbf{y}\|_2^2 + \mathbf{d}^T \mathbf{Zx}.$$

Consideramos la función interior,

$$\phi(t) = \frac{1}{2}\|\mathbf{x}\|_2^2 \cdot t + \frac{1}{2}\|\mathbf{XZx} - \mathbf{y}\|_2^2 + \mathbf{d}^T \mathbf{Zx},$$

que es lineal en t para cada x fijo y, por tanto, cóncava. Tenemos entonces que el mínimo puntual de una familia de funciones cóncavas es cóncava (ver [6]). Es decir, tenemos que $f_\gamma(\mathbf{z})$ es cóncava. Tenemos además que $f_\gamma := \min_{\mathbf{z} \in \mathcal{Z}_n^k} f_\gamma(\mathbf{z})$ es también cóncava en $\frac{1}{\gamma}$ por ser el mínimo de funciones cóncavas. Por esta concavidad, es un resultado estándar del análisis de sensibilidad que el conjunto de γ para el que un $\mathbf{z}$ particular es óptimo es un intervalo (posiblemente abierto) [4]. Teniendo en cuenta que el conjunto $\mathcal{Z}_n^k$ es finito obtenemos el resultado. □

Corolario 3.0.1. *Sea $\mathbf{z}^*(\gamma)$ una solución óptima del Problema $(\mathcal{P}_1)$ para γ fijo y sea $f_\gamma(\mathbf{z})$ el valor objetivo óptimo del Problema $(\mathcal{P}_2)$ para un γ fijo. Entonces, existe algún parámetro $\gamma_1 > 0$ tal que, para todo $\gamma \leq \gamma_1$ se tiene que:*

$$f_\gamma(\mathbf{z}^*(\gamma_1)) = f_\gamma(\mathbf{z}^*(\gamma)).$$

Capítulo 4

Resultados computacionales

En este capítulo se presentará la implementación en C++ del Algoritmo 1 desarrollado en la Sección 1.2.3. Posteriormente se evaluará la eficiencia del algoritmo con un ejemplo práctico con activos del índice S&P500.

4.1. Implementación

Empezamos definiendo las estructuras de datos con las que vamos a trabajar:

Datos: Contiene la información del problema.

```
1 struct Datos {  
2   int m, n, r, k;  
3   double gamma;  
4   vector <vector<double> > X;           // rxn  
5   vector <double> y;                   // r  
6   vector <double> d;                   // n  
7   vector <vector<double> > A;          // mxn  
8   vector <double> l;                   // m  
9   vector <double> u;                   // m  
10 };
```

- n: Número de activos candidatos
- k: Restricción de cardinalidad
- gamma: parámetro de regularización
- X: Matriz $X \in \mathbb{R}^{r \times n}$
- y: Vector $y \in \mathbb{R}^r$

- **d**: Vector $\mathbf{d} \in \mathbb{R}^n$
- **A**: Matriz $\mathbf{A} \in \mathbb{R}^{m \times n}$ de desigualdades lineales
- **l**: Vector $\mathbf{l} \in \mathbb{R}^m$ cota inferior de las desigualdades lineales
- **u**: Vector $\mathbf{u} \in \mathbb{R}^m$ cota superior de las desigualdades lineales

solProblemaDual: Almacena la solución del subproblema dual (evaluación de $f(\mathbf{z})$).

```

1  struct solProblemaDual {
2  double f_z;
3  vector<double> omega;
4  vector<double> grad;
5  bool factible=0;
6  };

```

- **f_z**: Valor de la función $f(\mathbf{z})$
- **omega**: Valor del vector omega
- **grad**: Valor del subgradiente
- **factible**: Indica si el problema es factible

solProblemaMin: Almacena la solución del problema de minimización.

```

1  struct solProblemaMin {
2  bool factible;
3  vector <double> z;
4  double theta;
5  solProblemaMin(const int n, double theta) : z(n), theta(
        theta), factible(0) {}
6  solProblemaMin(const vector<double>& z, double theta=-1e30
        ) : z(z), theta(theta), factible(0) {}
7  };

```

- **factible**: Indica si el problema es factible
- **z**: vector $\mathbf{z}$ solución del problema de minimización
- **theta**: Cota inferior θ actual.
- **solProblemaMin**: Constructor de estructura. Inicializa $\mathbf{z}$ y θ por copia. Inicializa θ a $-1e30$ y $\text{factible} = 0$.

solOA: Almacena el resultado final del algoritmo completo.

```

1  struct solOA {
2  double fOpt;
3  vector<double> omega;
4  vector<double> zOpt;
5  vector<double> xOpt;
6  vector<double> fz_hist;
7  vector<double> theta_hist;
8  solOA(const Datos& datos, int iterMax): zOpt(datos.n), xOpt(
    datos.n), omega(datos.n), fOpt(1e30) {
9      fz_hist.reserve(iterMax);
10     theta_hist.reserve(iterMax);
11 }
12 };

```

- fOpt: Valor óptimo de $f(\mathbf{z})$
- omega: Valor final de ω
- zOpt: Valor óptimo de $\mathbf{z}$
- xOpt: Valor óptimo de $\mathbf{x}$
- fz_hist: Histórico de valores de $f(\mathbf{z})$
- theta_hist: Histórico de valores de θ
- solOA: Constructor de estructura. Se inicializa zOpt, xOpt y omega con n elementos, fOpt = 1e30. Se reserva espacio para los vectores fz_hist y theta_hist igual al número de iteraciones.

Ya tenemos definidas todas las estructuras que vamos a necesitar. Procedemos a definir una clase para cada problema.

variablesDual: Clase correspondiente al subproblema de evaluación $f(\mathbf{z})$.

```

1  class variablesDual {
2      const double gamma05;
3  public:
4      const Datos& datos;
5      GRBModel problemaDual;
6      vector<GRBVar> alpha;
7      vector<GRBVar> omega;
8      vector<GRBVar> beta_l;

```

```

9      vector<GRBVar> beta_u;
10      GRBVar      lambda;
11      GRBQuadExpr obj;
12      variablesDual(GRBEnv& env, const Datos& datos) : datos(
          datos), problemaDual(env), alpha(datos.r), omega(datos.
          n), beta_l(datos.m), beta_u(datos.m), gamma05(datos.
          gamma * 0.5) {
13          problemaDual.set(GRB_IntParam_OutputFlag, 0);
14          \\ Declaracion variables
15          for (int i = 0; i < datos.r; i++) {
16              alpha[i] = problemaDual.addVar(-GRB_INFINITY,
                  GRB_INFINITY, 0.0, GRB_CONTINUOUS, "alpha_" +
                  to_string(i));
17          }
18          for (int i = 0; i < datos.n; i++) {
19              omega[i] = problemaDual.addVar(-GRB_INFINITY,
                  GRB_INFINITY, 0.0, GRB_CONTINUOUS, "omega_" +
                  to_string(i));
20          }
21          for (int i = 0; i < datos.m; i++) {
22              beta_l[i] = problemaDual.addVar(0.0, GRB_INFINITY,
                  0.0, GRB_CONTINUOUS, "Beta_l_" + to_string(i))
                  ;
23              beta_u[i] = problemaDual.addVar(0.0, GRB_INFINITY,
                  0.0, GRB_CONTINUOUS, "Beta_u_" + to_string(i))
                  ;
24          }
25          lambda = problemaDual.addVar(-GRB_INFINITY,
                  GRB_INFINITY, 0.0, GRB_CONTINUOUS, "lambda");
26          problemaDual.update();
27          // Funcion objetivo
28          // -1/2 alfa^T alfa
29          for (int i = 0; i < datos.r; i++) {
30              obj -= 0.5 * alpha[i] * alpha[i];
31          }
32          // y^T alpha
33          for (int i = 0; i < datos.r; i++) {
34              obj += datos.y[i] * alpha[i];
35          }
36          // Beta_l^T l
37          for (int i = 0; i < datos.m; i++) {
38              obj += beta_l[i] * datos.l[i];
39          }
40          // Beta_u^T u
41          for (int i = 0; i < datos.m; i++) {

```

```

42         obj -= beta_u[i] * datos.u[i];
43     }
44     // lambda
45     obj += lambda;
46     // Restricciones
47     for (int i = 0; i < datos.n; i++) {
48         GRBLinExpr rest;
49
50         // X^T alpha
51         for (int j = 0; j < datos.r; j++) {
52             rest += datos.X[j][i] * alpha[j];
53         }
54         // A^T (Beta_l-Beta_u)
55         for (int j = 0; j < datos.m; j++) {
56             rest += datos.A[j][i] * (beta_l[j] - beta_u[j]
57                                     );
58         }
59         // lambda e
60         rest += lambda;
61         // - d
62         rest -= datos.d[i];
63         // Anadimos restricciones para omega[i]
64         problemaDual.addConstr(omega[i] >= rest, "
65                               omega_restr_" + to_string(i));
66     }
67 }
68
69 solProblemaDual solve(const vector<double>& z) {
70     solProblemaDual resultado;
71     resultado.factible = false;
72     resultado.omega.assign(datos.n, 0.0);
73     resultado.grad.assign(datos.n, 0.0);
74     // - gamma/2 sum(zi wi^2)
75     GRBQuadExpr tempZ;
76     for (int i = 0; i < datos.n; i++) {
77         if (z[i] > 0.5) {
78             tempZ -= gamma05 * omega[i] * omega[i];
79         }
80     }
81     tempZ+=obj;
82     problemaDual.setObjective(tempZ, GRB_MAXIMIZE);
83     problemaDual.optimize();
84     int status = problemaDual.get(GRB_IntAttr_Status);
85     if (status == GRB_OPTIMAL || status == GRB_SUBOPTIMAL)
86     {
87         // Problema es factible

```

```

84         resultado.factible = true;
85         // Obtenemos valor funcion objetivo
86         resultado.f_z = problemaDual.get(
87             GRB_DoubleAttr_ObjVal);
88         // Extraemos valor variables
89         for (int i = 0; i < datos.n; i++) {
90             resultado.omega[i] = omega[i].get(
91                 GRB_DoubleAttr_X);
92             resultado.grad[i] = -gamma05 * resultado.omega
93                 [i] * resultado.omega[i];
94         }
95     }
96     else {
97         resultado.f_z = 1e30;    // Si no se alcanza
98         solucion optima o factible -> f(z) lo
99         establecemos inf
100     }
101     return resultado;
102 }
103 };

```

Esta clase encapsula el problema dual. Dado $\mathbf{z}$, calcula $f(\mathbf{z})$ y un subgradiente. El constructor de clase declara las variables, restricciones y función objetivo del problema. El método solve devuelve un objeto de la estructura solProblemaDual, resultado de resolver el problema de evaluar $f(\mathbf{z})$.

variablesMin: Clase del problema de minimización de θ .

```

1  class variablesMin {
2  const int n;
3  const int k;
4  int numCorte;
5  public:
6      GRBModel ProblemaTheta;
7      GRBVar theta;
8      vector<GRBVar> z;
9      variablesMin(GRBEnv& env, const Datos& datos) :
10          ProblemaTheta(env), z(datos.n), n(datos.n), numCorte(0), k
11          (datos.k) {
12          ProblemaTheta.set(GRB_IntParam_OutputFlag, 0);
13          // Declaramos variables
14          theta = ProblemaTheta.addVar(-GRB_INFINITY,
15              GRB_INFINITY, 0.0, GRB_CONTINUOUS, "theta");
16          for (int i = 0; i < n; i++) {
17              z[i] = ProblemaTheta.addVar(0.0, 1.0, 0.0,

```

```

15         GRB_BINARY, "z_" + to_string(i));
16     }
17     ProblemaTheta.update();
18     \\ Funcion objetivo
19     GRBLinExpr obj;
20     obj += theta;
21     ProblemaTheta.setObjective(obj, GRB_MINIMIZE);
22     // Restricciones
23     GRBLinExpr cardinalidad;
24     for (int i = 0; i < n; i++) {
25         cardinalidad += z[i];
26     }
27     ProblemaTheta.addConstr(cardinalidad <= k, "
28         cardinalidad");
29 }
30 solProblemaMin Solve(solProblemaDual& dual, solProblemaMin
31 & min) {
32     numCorte += 1;
33     solProblemaMin minNueva(min.z,min.theta);
34     GRBLinExpr restr;
35     restr += dual.f_z;
36     for (int i = 0; i < n; i++) {
37         restr += dual.grad[i] * z[i];
38         restr -= dual.grad[i] * min.z[i];
39     }
40     ProblemaTheta.addConstr(theta >= restr, "Corte_OA_" +
41         to_string(numCorte));
42     ProblemaTheta.optimize();
43     int status = ProblemaTheta.get(GRB_IntAttr_Status);
44     if (status == GRB_OPTIMAL || status == GRB_SUBOPTIMAL)
45     {
46         minNueva.theta = ProblemaTheta.get(
47             GRB_DoubleAttr_ObjVal);
48         for (int i = 0; i < n; i++) {
49             minNueva.z[i] = (z[i].get(GRB_DoubleAttr_X) >
50                 0.5) ? 1.0 : 0.0;
51         }
52         min.factible = 1;
53     }
54     else {
55         cout << "Problema_Min_Theta_infactible\n";
56     }
57     return minNueva;
58 }

```

Esta clase encapsula el problema de minimización de θ con los cortes proporcionados por los subgradiientes. El constructor declara las variables, las restricciones y la función objetivo. El método solve devuelve un objeto de la estructura solProblemaMin, resultado de minimizar θ sujeto a los cortes.

AlgoritmoOA: Clase del algoritmo de aproximación exterior.

```

1      class AlgoritmoOA {
2  public:
3      const Datos& datos;
4      variablesDual dual;
5      variablesMin min;
6      AlgoritmoOA(GRBEnv& env, const Datos& datos): datos(datos),
          dual(env, datos), min(env, datos) {
7      }
8      solOA solve(vector<double>& zinit, double epsilon, int
          iterMax) {
9          solOA sol(datos, iterMax);
10         sol.zOpt=zinit;
11         solProblemaMin solMin(zinit);
12         std::cout << "\n"
13             << std::setw(5) << "Iter"
14             << std::setw(16) << "f(z)_UB"
15             << std::setw(16) << "theta_LB"
16             << std::setw(12) << "Gap"
17             << "\n"
18             << std::string(49, '-') << "\n";
19         for (int t = 1; t <= iterMax; t++) {
20             // --- Paso 1: Evaluar f(z_actual) ---
21             solProblemaDual solDual;
22             try{
23                 solDual = dual.solve(solMin.z);
24             }
25             catch (GRBException& e) {
26                 cerr << "[Problema_Dual]_Gurobi_error_" << e.
                     getErrorCode() << ":_" << e.getMessage() <<
                     "\n";
27                 solDual.f_z = 1e30;
28             }
29             if (solDual.factible && solDual.f_z < sol.fOpt) {
30                 sol.fOpt = solDual.f_z;
31                 sol.zOpt= solMin.z;
32                 sol.omega = solDual.omega;
33             }
34             sol.theta_hist.push_back(solMin.theta);

```

```

35         sol.fz_hist.push_back(solDual.f_z);
36         double gap = (sol.fOpt < 1e29) ? (sol.fOpt -
37             solMin.theta) : 1e30;
38         std::cout << std::setw(5) << t
39             << std::setw(16) << std::setprecision(6) <<
40             sol.fOpt
41             << std::setw(16) << solMin.theta
42             << std::setw(12) << gap
43             << "\n";
44         // ---- Criterio de parada ----
45         if (gap <= epsilon) {
46             cout << "Convergencia_en_iteracion_" << t << "
47                 \n" << "|f(z)-theta|<=" << std::fixed <<
48                 epsilon << "\n";
49             break;
50         }
51         // ---- Paso 2: Resolver problema min theta ---
52         try{
53             solMin = min.Solve(solDual, solMin);
54         }
55         catch (GRBException& e) {
56             cerr << "[Problema_Theta]_Gurobi_error_" << e.
57                 getErrorCode() << ":" << e.getMessage() <<
58                 "\n";
59         }
60         if (t == iterMax) {
61             cout << "Maximo_iteraciones_alcanzado" << "\n"
62                 ;
63         }
64     }
65     return sol;
66 }

```

Esta clase encapsula el algoritmo de aproximación exterior desarrollado en la Sección 1.2.3. El constructor inicializa objetos de las estructuras variablesDual y variablesMin. El método solve devuelve un objeto de la estructura solOA, resultado final del algoritmo. El método en cada iteración resuelve el problema dual para $\mathbf{z}$ fijo y el problema de minimización de θ obteniendo así un nuevo $\mathbf{z}$ y un nuevo corte para el problema dual. El algoritmo cuenta con un test de parada cuando $f(\mathbf{z}) - \theta \leq \epsilon$.

4.2. Ejemplo práctico

Con el fin de evaluar la potencia del algoritmo, utilizaremos 500 activos del índice S&P500 sujetos a restricciones lineales triviales y a una restricción de cardinalidad de

10 activos. Véase la Figura 4.1. El S&P500 es uno de los principales índices bursátiles de Estados Unidos y agrupa las 500 empresas de mayor capitalización del mercado estadounidense. Se analizan distintos valores del parámetro γ . En primer lugar, el valor propuesto por D. Bertsimas y R. Cory-Wright, es $\gamma = \frac{100}{\sqrt{n}}$, que para $n = 500$ queda $\gamma = \frac{100}{\sqrt{500}} \approx 4,48$. Adicionalmente utilizaremos los valores $\gamma = 10$ y $\gamma = 11$ para observar la variación del número de iteraciones, el tiempo de ejecución y la asignación de activos en función del γ elegido.

```
int main()
{
    // Inicialización entorno Gurobi
    GRBEnv env;
    env.set(GRB_IntParam_OutputFlag, 0); // silenciar output de Gurobi
    // Tiempo
    auto inicio = std::chrono::system_clock::now();
    std::cout << "\n" << "Inicio: " << std::format("{:H:%M:%S}\n", inicio) << "\n";
    // Inicializamos z_hist
    vector<vector<double>> z_hist;
    Datos data;
    data.n = 500;
    data.r = 10;
    data.m = 1;
    data.k = 10;
    data.gamma = 4.48;
    data.X.resize(10);
    // FI: Mercado
    data.X[0] = {
        0.054289946, 0.051535919, 0.043388498, 0.053882888, 0.053989987, 0.050763677, 0.051617054, 0.050477357,
        0.051821685, 0.059790578, 0.053579252, 0.053148336, 0.047880887, 0.043291649, 0.048889704, 0.058165616,
        0.047990620, 0.055633558, 0.053431023, 0.048883942, 0.048284563, 0.051286273, 0.051692767, 0.051222550,
        0.042668328, 0.046522420, 0.047982321, 0.053372558, 0.051146344, 0.052284397, 0.054340792, 0.049615139,
        0.048227389, 0.044753388, 0.050192252, 0.047782810, 0.051252277, 0.049656822, 0.061813116, 0.053846025,
        0.051948428, 0.049187331, 0.054989253, 0.048868162, 0.045822722, 0.049386889, 0.053899436, 0.058938039,
        0.053780361, 0.051275288, 0.056277293, 0.055933855, 0.052595909, 0.049319019, 0.057472496, 0.047772637,
        0.053641135, 0.050262934, 0.048935661, 0.050899275, 0.054591642, 0.049599134, 0.055843289, 0.051749780,
        0.049158233, 0.046236152, 0.039902496, 0.053587580, 0.051155555, 0.050842577, 0.048825943, 0.043875774,
        0.043312087, 0.045958535, 0.046787663, 0.049689697, 0.050644973, 0.052883583, 0.048868872, 0.049932030,
        0.045494020, 0.048194887, 0.048537930, 0.054729153, 0.048974411, 0.043385525, 0.048235699, 0.047573627,
        0.051147289, 0.050231883, 0.043902974, 0.053878415, 0.050568844, 0.049591188, 0.051884181, 0.049597899,
        0.047718485, 0.053325852, 0.051334082, 0.045982196, 0.051569117, 0.043584906, 0.053428342, 0.048891722,
        0.048184437, 0.047879353, 0.048210257, 0.051635912, 0.049142391, 0.047531835, 0.047074393,
        0.048775736, 0.050335878, 0.048401722, 0.050734459, 0.053831883, 0.047296485, 0.049995666, 0.050764114,
        0.049777264, 0.052949739, 0.050455044, 0.047361443, 0.047861313, 0.036946424, 0.055187851, 0.048483130,
        0.042393467, 0.040424276, 0.041585081, 0.031571144, 0.033048721, 0.036574501, 0.033060142, 0.030885845,
        0.033035903, 0.028956040, 0.037652377, 0.035894394, 0.036527288, 0.040876563, 0.025286941, 0.028435892,
        0.034893812, 0.026153264, 0.033369445, 0.036092938, 0.029519042, 0.036961720, 0.030764251, 0.026848249,
        0.033851717, 0.036989915, 0.030682205, 0.037065413, 0.037173771, 0.037654669, 0.033602217, 0.034972328,
        0.035180926, 0.031314721, 0.043732985, 0.035441598, 0.034291996, 0.032861412, 0.028931877, 0.037746805,
        0.032801836, 0.026887878, 0.041178262, 0.028348288, 0.032094971, 0.030724555, 0.034044757, 0.033064294,
        0.035434302, 0.035060241, 0.026351612, 0.040903379, 0.038018180, 0.032253196, 0.035445905, 0.032365339,
        0.036535079, 0.050651733, 0.041876640, 0.045545228, 0.042152213, 0.038446011, 0.043168702, 0.049638866,
        0.050598734, 0.048571345, 0.053548252, 0.042351994, 0.046519012, 0.050786580, 0.043655385, 0.046141881,
        0.048596575, 0.048223837, 0.046935888, 0.048189255, 0.043219765, 0.039538870, 0.041941637, 0.046360600,
        0.047762843, 0.051397240, 0.038318479, 0.048936392, 0.049158927, 0.047445617, 0.053799087, 0.042387424,
        0.041262583, 0.043273558, 0.049052400, 0.041929931, 0.047824596, 0.042762600, 0.054407461, 0.051369673,
        0.047942435, 0.053572998, 0.048844024, 0.045335390, 0.049872972, 0.048699124, 0.046972185, 0.045709583,
        0.045028690, 0.039043739, 0.047441623, 0.043897271, 0.043968900, 0.043523387, 0.036799429, 0.046793280,
        0.043988849, 0.041851593, 0.041880904, 0.047758449, 0.048285596, 0.049165177, 0.040637041, 0.036068529,
        0.045208884, 0.050468855, 0.036887288, 0.043706728, 0.049141099, 0.033649025, 0.046662988, 0.038338970,
        0.045433384, 0.038768812, 0.049142233, 0.036464487, 0.041131051, 0.039228580, 0.042869942, 0.043725217,
        0.047656437, 0.047636332, 0.041552686, 0.040127867, 0.048208937, 0.042379316, 0.044877737, 0.049870673,
        0.039689409, 0.042344780, 0.044152497, 0.046633640, 0.043099936, 0.043194196, 0.040488047, 0.050857832,
        0.045519222, 0.039136129, 0.044923752, 0.047823784, 0.047065531, 0.041918535, 0.039256004, 0.043774737,
        0.053193235, 0.037476615, 0.041964084, 0.037865277, 0.037349111, 0.041859490, 0.040511189, 0.037893889,
        0.047022036, 0.039516122, 0.038638042, 0.038526527, 0.044858692, 0.045027449, 0.042011528, 0.046189213,
        0.041289575, 0.037667891, 0.040877704, 0.038650575, 0.048824040, 0.044387193, 0.036439471, 0.040042915,
    };
}
```

Figura 4.1: Activos elegidos

A continuación observamos los distintos resultados que obtenemos en función de la elección de γ . Véanse las Figuras 4.2, 4.3 y 4.4.


```

Inicio: 15:37:40.1547335

=== Outer-Approximation (Gurobi): Sparse Portfolio Selection ===
n=500 k=10 gamma=4.48

  Iter      f(z) [UB]      theta [LB]      Gap
  -----
    1      0.0492871      -1e+30      1e+30
    2      0.035979      0.0313741  0.00460486
    3      0.035979      0.035979      0
Convergencia en iteracion 3
|f(z)-theta|<=0.000000

=== Cartera optima ===
Activos seleccionados (z*): 3 6 20 31 65 179 209 220 234 478
f(z*)=0.035979
x[3] = 0.096584
x[6] = 0.096815
x[20] = 0.094922
x[31] = 0.105458
x[65] = 0.093991
x[179] = 0.091871
x[209] = 0.128867
x[220] = 0.102590
x[234] = 0.099919
x[478] = 0.088982

Final: 15:37:40.5915198

Duracion: 0.436786 segundos

```

Figura 4.2: $\gamma = 4,48$

```

=== Outer-Approximation (Gurobi): Sparse Portfolio Selection ===
n=500 k=10 gamma=10

Iter      f(z) [UB]      theta [LB]      Gap
-----
  1      0.0429354      -1e+30      1e+30
  2      0.0296616      0.0199933  0.00966827
  3      0.0296616      0.028848  0.000813521
  4      0.0296616      0.0294014  0.000260118
  5      0.0296616      0.0294953  0.000166239
  6      0.0296616      0.0294969  0.000164661
  7      0.0296616      0.0295011  0.000160467
  8      0.0296616      0.0295128  0.000148801
  9      0.0296616      0.0295176  0.00014391
 10      0.0296616      0.0295312  0.000130396
 11      0.0296616      0.029547  0.000114537
 12      0.0296616      0.0295472  0.000114355
 13      0.0296616      0.029556  0.000105504
 14      0.0296616      0.0295819  7.96777e-05
 15      0.0296616      0.0295862  7.54016e-05
 16      0.0296616      0.0295873  7.42182e-05
 17      0.0296616      0.0295895  7.20786e-05
 18      0.0296616      0.0295915  7.00843e-05
 19      0.0296616      0.0296146  4.69707e-05
 20      0.0296616      0.0296186  4.2947e-05
 21      0.0296616      0.0296217  3.98278e-05
 22      0.0296616      0.0296227  3.88475e-05
 23      0.0296616      0.0296228  3.871e-05
 24      0.0296616      0.0296338  2.77191e-05
 25      0.0296616      0.0296387  2.28257e-05
 26      0.0296616      0.0296403  2.12178e-05
 27      0.0296616      0.0296461  1.54426e-05
 28      0.0296616      0.0296537  7.87402e-06
 29      0.0296616      0.0296537  7.87402e-06
 30      0.0296616      0.0296537  7.87402e-06
 31      0.0296616      0.0296556  5.98348e-06
 32      0.0296616      0.0296607  8.87649e-07
 33      0.0296616      0.0296616      0

Convergencia en iteracion 33
|f(z)-theta|<=0.000000

=== Cartera optima ===
Activos seleccionados (z*): 3 6 20 31 65 179 209 220 234 478
f(z*)=0.029662
x[3] = 0.092359
x[6] = 0.092918
x[20] = 0.088705
x[31] = 0.112192
x[65] = 0.086604
x[179] = 0.081886
x[209] = 0.164367
x[220] = 0.105753
x[234] = 0.099769
x[478] = 0.075447

Final: 15:36:47.2168443
Duracion: 1.012413 segundos

```

Figura 4.3: $\gamma = 10$

```

70      0.0291787      0.0291435 3.5149e-05
71      0.0291787      0.0291468 3.18357e-05
72      0.0291787      0.029146 3.26472e-05
73      0.0291787      0.0291466 3.20753e-05
74      0.0291787      0.0291491 2.95322e-05
75      0.0291787      0.0291503 2.83501e-05
76      0.0291787      0.0291505 2.81261e-05
77      0.0291787      0.0291527 2.59989e-05
78      0.0291787      0.0291539 2.48018e-05
79      0.0291787      0.0291562 2.24098e-05
80      0.0291787      0.0291569 2.17884e-05
81      0.0291787      0.0291582 2.04272e-05
82      0.0291787      0.02916 1.86151e-05
83      0.0291787      0.0291609 1.77421e-05
84      0.0291787      0.029164 1.46637e-05
85      0.0291787      0.029164 1.46638e-05
86      0.0291787      0.029164 1.46637e-05
87      0.0291787      0.029164 1.46637e-05
88      0.0291787      0.0291787 -3.46945e-18
Convergencia en iteracion 88
|f(z)-theta|<=0.000000

=== Cartera optima ===
Activos seleccionados (z*): 3 6 20 31 65 179 209 220 234 478
f(z*)=0.029179
x[3] = 0.091591
x[6] = 0.092215
x[20] = 0.087583
x[31] = 0.113412
x[65] = 0.085268
x[179] = 0.080080
x[209] = 0.170790
x[220] = 0.106323
x[234] = 0.099735
x[478] = 0.073001

Final: 15:34:49.7837214
Duracion: 11.165731 segundos

```

Figura 4.4: $\gamma = 11$

Se observa que, en los tres casos, los activos seleccionados permanecen invariantes a pesar de que las asignaciones individuales a cada uno de ellos varían. Como se apuntó en el Capítulo 3, cabe esperar que dichos activos correspondan con la solución del problema sin término de regularización. En consecuencia, es posible resolver el problema desregularizado con z fijo y obtener así la asignación de activos óptima del problema sin regularización de manera más eficiente.




Figura 4.5: Convergencia de $f(\mathbf{z})$ (cota superior) y θ (cota inferior) para $\gamma = 11$.




Figura 4.6: Evolución del gap $f(\mathbf{z}) - \theta$ para $\gamma = 11$.

Conclusiones

A lo largo de este trabajo se ha desarrollado la teoría necesaria para comprender el algoritmo de aproximación exterior propuesto por Dimitris Bertsimas y Ryan Cory-Wright en “A Scalable Algorithm for Sparse Portfolio Selection” [3]. Dicho algoritmo permite resolver de manera eficiente, desde el punto de vista computacional, el problema de selección de carteras con restricción de cardinalidad y desigualdades lineales, aprovechando estructuras y propiedades específicas del problema. Además, se ha observado que, mediante una correcta selección del término de regularización, es posible recuperar la solución del problema original. Se ha implementado dicho algoritmo en C++ con el solver comercial GUROBI. Además se ha observado su eficiencia a la hora de resolver de problemas con hasta 500 activos.

El marco teórico desarrollado en este trabajo permite implementar el algoritmo de aproximación exterior, que puede mejorarse mediante técnicas de *warm start* y el uso de cota inferiores basadas en programación cónica de segundo orden. Estas mejoras, junto con el algoritmo desarrollado en este trabajo, ofrecen una solución escalable para el problema de selección de carteras dispersas.

Bibliografía

- [1] Adi Ben-Israel and Thomas NE Greville. *Generalized inverses: theory and applications*. Springer, 2003.
- [2] Dimitri Bertsekas. Nonlinear Programming, 01 2003.
- [3] Dimitris Bertsimas and Ryan Cory-Wright. A scalable algorithm for sparse portfolio selection. *INFORMS Journal on Computing*, 34(3):1489–1511, 2022.
- [4] Dimitris Bertsimas and John N Tsitsiklis. *Introduction to linear optimization*, volume 6. Athena scientific Belmont, MA, 1997.
- [5] Daniel Bienstock. Computational study of a family of mixed-integer quadratic programming problems. *Mathematical Programming*, 74(2):121–140, 1996.
- [6] Stephen Boyd and Lieven Vandenberghe. *Convex optimization*. Cambridge University Press, 2004.
- [7] T-J Chang, Nigel Meade, John E Beasley, and Yazid M Sharaiha. Heuristics for cardinality constrained portfolio optimisation. *Computers & Operations Research*, 27(13):1271–1302, 2000.
- [8] Marco A Duran and Ignacio E Grossmann. An outer-approximation algorithm for a class of mixed-integer nonlinear programs. *Mathematical Programming*, 36(3):307–339, 1986.
- [9] Michael R Fellows and Neal Koblitz. Fixed-parameter complexity and cryptography. In *International Symposium on Applied Algebra, Algebraic Algorithms, and Error-Correcting Codes*, pages 121–131. Springer, 1993.
- [10] Jianjun Gao and Duan Li. Optimal cardinality constrained portfolio selection. *Operations Research*, 61(3):745–761, 2013.
- [11] Michael R Garey and David S Johnson. *Computers and intractability*, volume 29. wh freeman New York, 2002.
- [12] Nancy L Jacob. A limited-diversification portfolio selection model for the small investor. *The Journal of Finance*, 29(3):847–856, 1974.

-
- [13] Alan J Laub. The moore-penrose pseudoinverse. *Math 33A*, 2011.
 - [14] David C. Lay, Steven R. Lay, and Judi J. McDonald. *Linear Algebra and Its Applications*. Pearson, 5 edition, 2015.
 - [15] Harry Markowitz. Portfolio selection. *The Journal of Finance*, 7(1):77–91, 1952.
 - [16] LUIS MIGUEL MERINO GONZALEZ and EVANGELINA SANTOS ALAEZ. *Álgebra Lineal con métodos elementales*. Ediciones Paraninfo, SA, 2006.
 - [17] Andre F Perold. Large-scale portfolio optimization. *Management Science*, 30(10):1143–1160, 1984.
 - [18] Michael Sipser. Introduction to the theory of computation. *ACM Sigact News*, 27(1):27–29, 1996.